

Predição e Otimização de Intervenções para Redução da Evasão Escolar no Brasil

Carlos Eduardo Cavalieri Furtado - RA 219748

Orientador: Santiago Valdés Ravelo

Resumo

A evasão escolar é um dos principais desafios enfrentados pela educação básica brasileira, afetando milhões de estudantes e comprometendo o desenvolvimento social e econômico do país. Este projeto tem como objetivo desenvolver um sistema integrado de predição de risco de evasão escolar e de otimização da alocação de recursos para intervenções preventivas. Utilizando dados do Censo Escolar, IBGE e outras fontes socioeconômicas, serão treinados modelos de aprendizado de máquina para identificar alunos em situação de risco. Em seguida, será desenvolvido um modelo de otimização combinatória para a alocação eficiente de recursos (como bolsas, transporte escolar e reforço pedagógico), visando a redução do risco de abandono. A proposta se diferencia por integrar abordagens de aprendizado de máquina e Pesquisa Operacional, com foco na aplicabilidade prática em políticas públicas. A metodologia envolve ainda a explicabilidade dos modelos e simulações de impacto, permitindo um diálogo entre o desenvolvimento técnico e a gestão pública.

Palavras-chave: Evasão escolar; Aprendizado de máquina; Otimização combinatória; Alocação de recursos; Programação linear inteira; Políticas públicas educacionais.

1. Introdução e Motivação

A definição do termo Evasão Escolar (EE) apresenta diferenças entre países e agências internacionais, mas que captura um problema educacional recorrente em todo o mundo: a saída antecipada de estudantes do sistema de ensino. Em nível mundial, a Organização das Nações Unidas para a Educação, a Ciência e a Cultura (UNESCO), por meio de seu Instituto Internacional de Planejamento Educacional (IIEP), fornece uma definição fundamental, que serve como referência para outras instituições. Ela define os "evadidos" como indivíduos que abandonam a escola antes da conclusão de uma determinada etapa da educação ou saem em algum ponto intermediário de um ciclo escolar (Sauvageot, 1996). O Centro Nacional de Estatísticas da Educação dos Estados Unidos (NCES) oferece uma definição menos abrangente, considerando jovens de 15 a 24 anos (National Center for Education Statistics (NCES), 2019), enquanto o Gabinete de Estatísticas da União Europeia (Eurostat) considera estudantes de 18 a 24 anos (Eurostat, 2024).

No Brasil, desde 2021 o Ministério da Educação (MEC) e o Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP) definem a Evasão Escolar como a condição do estudante que, após ter abandonado a escola ou sido reprovado em determinado ano letivo, não realiza a matrícula no ano subsequente para dar continuidade aos estudos (Ministério da Educação (Brasil), 2021). De forma análoga, no ensino superior considera-se evadido o aluno que desvinculou-se do curso antes de concluí-lo. Essa definição mais ampla, que engloba desde o ensino básico ao ensino superior, será o conceito utilizado neste estudo, dada a utilização de dados da população brasileira.

A Evasão Escolar tem impactos econômicos consideráveis na sociedade. De acordo com Levin et al. (2007), para cada grupo de jovens de 20 anos que evade o ensino médio, a consequência fiscal é de US\$ 148 bilhões em receitas tributárias perdidas e gastos públicos adicionais ao longo da vida. No Brasil, o custo para a sociedade por jovem que não conclui a educação básica é de R\$395 mil, segundo Paes de Barros et al. (2021), sendo que aproximadamente 1,3 milhão de estudantes abandonam a escola todos os anos (INEP, 2023).

Além do impacto coletivo, as jovens que deixam a escola precocemente também enfrentam diversas consequências individuais. Do ponto de vista de renda e ocupação, esse comportamento está associado a maiores taxas de desemprego, trabalhos precários e menores salários (Bangquiao and Galigao, 2025). Não obstante, a EE resulta na perda de 3,2 anos de vida e 3,3 anos de vida saudável (Paes de Barros et al., 2021), além de estar associada a um aumento de 23,8% na probabilidade de cometer um crime quando adulto (Dragone et al., 2021).

Diversas abordagens têm sido propostas para a identificação precoce de alunos em risco de evasão. O uso de algoritmos de aprendizado de máquina tem se mostrado promissor nesse sentido, com destaque para técnicas como Random Forest, Gradient Boosting e Redes Neurais (Colpo, 2021; Silva et al., 2023; Romero and Liao, 2025; Camargos and Silveira, 2025). No entanto, a maioria das soluções desenvolvidas ainda se limita à etapa de predição, não avançando para a proposição de intervenções otimizadas baseadas nos resultados obtidos.

No contexto de Evasão Escolar, existe uma vasta literatura que utiliza de abordagens baseadas em estudos experimentais, quasi-experimentais e revisões sistemáticas com meta-análises para definir o impacto e alocação de intervenções (Pellegrini et al., 2025).

Entretanto, essas abordagens têm limitações quanto a escalabilidade e interação entre múltiplos tipos de intervenção.

Para atacar esse problema, diversas abordagens da área de Pesquisa Operacional (PO) podem ser aplicadas. Apesar de não existir ainda uma utilização formal dessas técnicas para o Problema da Evasão Escolar (PEE), a aplicação de PO no contexto educacional, mais especificamente no planejamento e alocação de recursos, tem atraído grande interesse da comunidade científica. Dentre os métodos utilizados, formulações como problemas de Programação Linear Inteira Mista, heurísticas e metaheurísticas estão entre as estratégias mais frequentemente usadas (Johnes, 2015; Petropoulos et al., 2024).

Este projeto propõe uma abordagem que combina aprendizado de máquina com técnicas de Pesquisa Operacional. A proposta é construir não apenas um modelo preditivo robusto, mas também um sistema de apoio à decisão que auxilie gestores educacionais na alocação eficiente de recursos para intervenções preventivas. A justificativa reside na necessidade de políticas públicas mais eficientes e baseadas em evidências, capazes de reduzir significativamente os índices de Evasão Escolar. Além disso, a definição do problema de alocação de intervenções preventivas, como descrita na literatura e apresentada nesta proposta, é computacionalmente complexa. Isso significa que, para instâncias realistas com milhares de alunos e múltiplos tipos de intervenções, encontrar soluções ótimas por métodos exatos torna-se impraticável em tempo razoável. Portanto, a adoção de heurísticas e metaheurísticas se justifica como estratégia viável para obtenção de soluções eficientes e escaláveis.

O restante deste documento está organizado da seguinte forma: após a introdução, os objetivos da pesquisa são descritos, seguidos das abordagens e métodos que serão utilizados; em seguida, o Problema da Evasão Escolar é formalmente definido; na seção seguinte os resultados preliminares são expostos, contendo a prova de NP-dificuldade e a formulação matemática proposta; Finalmente, o plano e cronograma de trabalho são apresentados na última seção.

2. Objetivos

Este trabalho tem como objetivo geral desenvolver um sistema integrado que combine técnicas de aprendizado de máquina e Pesquisa Operacional para abordar o problema da evasão escolar, buscando não apenas identificar estudantes em risco, mas também otimizar a alocação de recursos para intervenções preventivas de forma eficiente e escalável.

Em relação à componente preditiva, espera-se implementar modelos que têm como entrada os dados do Censo Escolar fornecidos pelo INEP e têm como saída: a probabilidade de evasão escolar inicial; e a redução percentual dessa probabilidade dada uma intervenção. Além disso, busca-se construir modelos que alcancem um equilíbrio entre acurácia preditiva e interpretabilidade. Enquanto algoritmos complexos como redes neurais e métodos *ensemble* frequentemente apresentam desempenho superior em termos de métricas de classificação, a natureza do problema educacional exige que os fatores determinantes do risco sejam compreensíveis para gestores e formuladores de políticas públicas. Assim, o trabalho explorará tanto modelos originalmente interpretáveis, como GAMs e árvores de decisão, quanto técnicas de explicabilidade aplicadas a modelos mais complexos, utilizando ferramentas como SHAP e LIME para extrair informações sobre os principais

determinantes da evasão.

Para a componente de otimização, o objetivo central é desenvolver métodos computacionais que produzam soluções de alta qualidade para o problema de alocação de intervenções em tempo computacional viável, considerando a complexidade do problema. Dado que instâncias realistas envolvem milhares de estudantes e múltiplos tipos de intervenções com diferentes custos e capacidades, o trabalho propõe implementar tanto formulações exatas quanto heurísticas e meta-heurísticas, permitindo que gestores educacionais obtenham planos de intervenção otimizados mesmo para redes escolares de grande porte.

Por fim, o trabalho visa estabelecer uma ponte entre o desenvolvimento técnico-científico e a aplicabilidade prática em políticas públicas educacionais, fornecendo não apenas modelos matemáticos robustos, mas também diretrizes claras para sua implementação em diferentes contextos, sempre mantendo o foco na redução efetiva dos índices de evasão escolar através de decisões baseadas em evidências quantitativas.

3. Abordagens e Métodos

3.1 Bases de Dados

As principais fontes de dados serão o Censo Escolar e o Censo da Educação Superior (INEP, 2025), mantidos pelo INEP, que fornecem informações detalhadas e abrangentes sobre o sistema educacional brasileiro. Estas bases incluem dados essenciais sobre matrícula dos estudantes, indicadores de rendimento escolar como aprovação, reprovação e abandono, além de informações sobre movimento escolar que permitem rastrear transferências e desligamentos. Os Censos também disponibilizam dados georreferenciados sobre a localização das instituições de ensino e informações detalhadas sobre infraestrutura, incluindo disponibilidade de laboratórios, bibliotecas, quadras esportivas, acesso à internet e condições básicas como água, energia elétrica e saneamento. Ambas as bases de dados são de acesso público.

Esta pesquisa utilizará exclusivamente dados secundários já coletados pelo INEP no exercício de suas atribuições legais de realização dos Censos Educacionais. O acesso aos microdados protegidos ocorrerá mediante autorização formal e exclusivamente na sala segura do Serviço de Acesso a Dados Protegidos (SEDAP) do INEP, em Brasília-DF, em conformidade com a Portaria INEP nº 637/2019, a Lei nº 12.527/2011 (Lei de Acesso à Informação) e a Lei nº 13.709/2018 (Lei Geral de Proteção de Dados). As bases de dados disponibilizadas já passaram por processo de desidentificação conduzido pelo INEP, não contendo informações pessoais identificáveis. Todos os resultados serão apresentados exclusivamente em formato agregado, respeitando unidades amostrais mínimas que impeçam a identificação de indivíduos ou instituições. Não haverá coleta primária de dados, contato com participantes ou qualquer forma de intervenção, caracterizando a pesquisa como de risco mínimo.

Complementando os dados educacionais, serão utilizadas bases socioeconômicas da Pesquisa Nacional por Amostra de Domicílios (PNAD) Contínua e do Instituto Brasileiro de Geografia e Estatística (IBGE). Estas fontes fornecem indicadores socioeconômicos regionais fundamentais para compreender o contexto no qual os estudantes estão inseridos, incluindo informações sobre condições domiciliares, acesso a serviços básicos, composição

familiar e renda per capita.

3.2 Modelos de Predição

A literatura sobre predição de evasão escolar abrange um vasto espectro de algoritmos de aprendizado de máquina, que podem ser categorizados com base em sua complexidade e interpretabilidade. A evolução da pesquisa na área demonstra uma preocupação com o equilíbrio entre a precisão das predições e a capacidade de compreender a classificação por trás delas. Essa compreensão é crucial em contextos de políticas públicas, pois permite que os tomadores de decisão compreendam quais fatores demográficos, socioeconômicos ou de desempenho acadêmico estão sendo mais ponderados pelo modelo (Romero and Liao, 2025).

Algoritmos ensemble (Random Forest, Gradient Boosting) e redes neurais tendem a atingir maior precisão preditiva, mas são mais difíceis de interpretar. Seo et al. (2024); Villar and de Andrade (2024) observam que Random Forest e XGBoost alcançam as maiores taxas de acerto na predição de evasão, enquanto a regressão logística e árvores de decisão, ainda que menos precisos, permitem entendimento intuitivo do risco pela análise de pesos ou regras de decisão. Liu et al. (2025) reforçam que, embora modelos complexos de *deep learning* sejam eficazes, sua baixa interpretabilidade dificulta aplicações práticas.

Para contornar a limitação de interpretabilidade dos modelos avançados, adotam-se técnicas XAI (Explainable AI) como SHAP (SHapley Additive exPlanations), LIME (Local Interpretable Model-agnostic Explanations), Partial Dependent Plots (PDPs) e Permutation Importance. Estas técnicas geram explicações que quantificam a contribuição de cada variável na predição (Quimiz-Moreira et al., 2025).

Uma tendência recente na literatura é a utilização de GAMs (Generalized Additive Models) para combinar qualidade de predição e interpretabilidade, assim como suas implementações mais sofisticadas baseadas em boosting de árvores, como EBMs (Explainable Boosting Machines). Romero and Liao (2025); Camargos and Silveira (2025) mostraram que essas abordagens conseguem competir com modelos de "caixa-preta", mas são diretamente interpretáveis.

No contexto do PEE, uma vantagem é que os classificadores binários geralmente fornecem, além da classe prevista, uma probabilidade associada a cada instância. Essas probabilidades podem ser interpretadas diretamente como um score de risco de evasão. Liu et al. (2025) aplicam regressão logística para estimar a probabilidade de aprovação ou não de alunos e recomendam usar essa probabilidade como indicativo de risco futuro de evasão. Da mesma forma, qualquer modelo de classificação permite extrair probabilidades (via softmax ou estimativas de frequência) que servem para ordenação dos alunos por vulnerabilidade, sendo de grande valor para um modelo de otimização em alocação de recursos.

Para o Problema de Evasão Escolar serão implementados e comparados diversos algoritmos, como GAMs, Random Forests, Gradient Boosting Trees e redes neurais. A avaliação de performance dos modelos será conduzida utilizando métricas apropriadas para problemas de classificação desbalanceada, considerando que a evasão escolar, embora significativa em números absolutos, representa uma proporção relativamente pequena do total de estudantes. Serão calculadas métricas como AUC-ROC, F1-score, precisão e recall.

Um aspecto crucial do projeto será a aplicação de técnicas de explicabilidade e interpretabilidade dos modelos, utilizando técnicas como Permutation Importance, PDPs, SHAP e LIME. Essas ferramentas permitirão não apenas identificar quais variáveis são mais importantes para as previsões, mas também compreender como diferentes fatores interagem para aumentar ou diminuir o risco de evasão.

3.3 Modelos de Intervenção

Métodos Tradicionais

A literatura sobre modelagem de intervenções educacionais para combate à evasão escolar tem evoluído significativamente nas últimas décadas, incorporando métodos cada vez mais sofisticados para determinar não apenas quais intervenções aplicar, mas também como alocá-las de forma otimizada entre diferentes populações estudantis (Wilson et al., 2011; Marius Proftoiu et al., 2024).

Historicamente, métodos experimentais e quasi-experimentais têm sido os mais utilizados para alocação de intervenções. Nesse contexto, os Ensaios Controlados Randomizados (RCTs) representam o padrão-ouro, envolvendo a alocação aleatória de indivíduos ou grupos a condições de intervenção e controle, permitindo comparações robustas de resultados. Entretanto, quando não é possível realizar RCTs, são utilizados métodos quasi-experimentais que buscam aproximar a inferência causal sem randomização completa, utilizando estratégias estatísticas sofisticadas para controlar fatores confundidores. (Pellegrini et al., 2025).

No entanto, as abordagens tradicionais frequentemente enfrentam limitações em termos de escalabilidade. Wilson et al. (2011) conduziram uma meta-análise de estudos com métodos experimentais e quase-experimentais, demonstrando que a maioria das intervenções produz efeitos positivos na prevenção da evasão escolar, independentemente de seu tipo. Contudo, os autores destacam a existência da necessidade de que os tomadores de decisão considerem a relação custo-benefício dos programas ao realizar a alocação de recursos, de modo a melhor atender às necessidades locais e às capacidades e recursos disponíveis dos implementadores.

Mais adiante, métodos experimentais e quasi-experimentais também apresentam dificuldade em compreender as interações complexas entre múltiplos tipos de intervenções. Na meta-análise realizada por Freeman and Simonsen (2015), é apresentado que apesar da literatura destacar a importância de avaliação de múltiplos fatores de risco em conjunto, a maior parte da produção científica foca em apenas um único componente e com um pequeno grupo de intervenções, dificultando a transição para cenários reais. Os esforços se concentram principalmente em avaliar o impacto de uma intervenção predefinida, em vez de otimizar a alocação de recursos para inúmeras intervenções potenciais em uma população estudantil diversificada.

Pesquisa Operacional

O caráter público e a relevância econômica da educação fazem dela um campo onde as ferramentas de Pesquisa Operacional são especialmente úteis (Petropoulos et al., 2024). Apesar da literatura não apresentar uma abordagem formal de PO para o problema de

evasão escolar, diversos trabalhos abordam problemas semelhantes no contexto educacional e que tem grande correlação com o PEE (Johnes, 2015).

Um problema particularmente similar ao problema proposto neste estudo é o problema de planejamento e alocação de recursos (financeiros, humanos ou operacionais). Petropoulos et al. (2024); Johnes (2015) apresentam diversos contextos desse problema, como por exemplo a alocação de investimentos públicos entre escolas sob restrições de orçamento, atribuição de professores e turmas sob restrições diversas, entre outros.

Programação Linear Inteira (PLI) é regularmente usada para planejamento e atribuição no contexto educacional. Cataldo et al. (2017) apresentam uma formulação PLI para o problema de alocação de salas, exames e cursos em uma instituição de ensino superior. Os resultados mostram que, apesar de o modelo ser capaz de gerar soluções melhores que o método manual utilizado pela universidade, a formulação PLI apresenta limitações de escalabilidade.

Nesse sentido, heurísticas e metaheurísticas são amplamente utilizadas para problemas complexos, onde encontrar boas soluções em tempo hábil é inviável. Cobacho et al. (2010) utilizaram SSPMO (Scatter Tabu Search Procedure for Multiobjective Optimization), um método híbrido que combina busca dispersa e memória adaptativa da tabu search. Essa abordagem é especialmente eficaz para problemas não lineares, contínuos e de múltiplos objetivos. No estudo, ela foi aplicada para resolver o modelo de planejamento de investimento público federal no México, que buscava simultaneamente melhorar quatro indicadores nacionais e reduzir desigualdades regionais nesses mesmos indicadores.

Qu et al. (2015) propõem uma hiper-heurística baseada em algoritmos de estimação de distribuições (EDA-HH) para o problema de alocação de exames. Nos experimentos, a EDA-HH foi testada em 13 instâncias-padrão e também em sua variante de coloração de grafos. Os resultados mostraram que a heurística foi consistente em todas as instâncias, obtendo soluções competitivas em relação às melhores da literatura e superando outras abordagens hiper-heurísticas em termos de generalidade.

Neste trabalho, o Problema de Evasão Escolar será formulado como um problema de Programação Linear Inteira. Esta formulação captura a natureza combinatória do problema, onde é necessário decidir quais estudantes devem receber quais tipos de intervenções, considerando limitações de recursos e maximizando o impacto na redução da evasão escolar. A implementação e resolução do modelo serão realizadas utilizando solvers de otimização estado-da-arte como Gurobi ou CPLEX.

Reconhecendo que para instâncias muito grandes (milhares de alunos e múltiplas intervenções) a solução exata pode ser computacionalmente proibitiva, serão também desenvolvidos métodos heurísticos e meta-heurísticos. Para isso serão avaliados inicialmente diferentes famílias de abordagens, como evolutivas, baseadas em vizinhança, por intensificação e diversificação, entre outras. Em seguida, a família que apresentar desempenho inicial mais promissor será explorada exaustivamente.

3.4 Forma de Análise dos Resultados

A avaliação dos resultados será feita em duas frentes. Na parte preditiva, será realizada uma análise quantitativa com validação cruzada, comparando o desempenho dos diferentes modelos. O uso de métodos de explicabilidade permitirá compreender a importância relativa das variáveis, facilitando a comunicação com formuladores de políticas.

Na parte de otimização, serão realizadas simulações baseadas em diferentes restrições orçamentárias e políticas de prioridade. O desempenho do modelo será avaliado em termos de cobertura, custo total e impacto na evasão prevista. Estima-se também a redução potencial de evasão em diferentes cenários, permitindo uma análise de sensibilidade dos parâmetros e validação da robustez da proposta. Serão discutidos também os limites éticos e operacionais do uso de modelos automatizados em políticas públicas.

Por fim, serão extraídas recomendações práticas para a implementação dos modelos em ambientes reais, considerando aspectos técnicos, sociais e políticos. O projeto se propõe a servir como base para políticas públicas baseadas em evidência, com potencial de replicação em diferentes contextos estaduais e municipais.

Garantias de Privacidade nos Resultados:

Apenas resultados agregados serão extraídos da sala segura do SEDAP. Todos os outputs passarão por revisão técnica antes da liberação, garantindo que:

- Nenhum dado individual seja identificável
- Tabelas contenham no mínimo 3 indivíduos por célula em agregações municipais, ou 10 indivíduos em agregações menores (escolas, coortes)
- Não sejam divulgados valores máximos/mínimos que possam identificar indivíduos
- Rankings ou ordenações que possam identificar instituições específicas sejam evitados

4. O Problema de Evasão Escolar

4.1 Definição

A **Evasão Escolar** é definida como a "situação do aluno que abandonou a escola ou reprovou em determinado ano letivo, e que, no ano seguinte, não efetuou a matrícula para dar continuidade aos estudos", de acordo com o Ministério da Educação (Brasil) (2021). Dessa forma, fica evidente que a entrada do problema deve integrar um **conjunto de alunos regularmente matriculados** (A).

Mais adiante, Vasconcelos et al. (2023) demonstram que os alunos podem ter diferentes riscos iniciais de evasão, dependentes de uma série de fatores e relacionamentos entre esses fatores. Logo, faz-se necessária a inclusão de um **risco inicial de evasão** (r).

Acerca de intervenções, a literatura disponível é extensa. Eslamian et al. (2023); Wilson et al. (2011); Freeman and Simonsen (2015) revisaram a produção científica disponível e mostraram que existe um **conjunto de intervenções** (I) que possuem impacto positivo na redução da evasão escolar e que essas intervenções tem impactos diferentes, justificando a inclusão da **efetividade esperada de aplicar a intervenção i ao aluno a** (e) e de considerar apenas o **subconjunto de intervenções efetivas para um determinado aluno** (S). Além disso, os artigos destacam que as intervenções podem ser agrupadas por tipos e cada aluno pode ter mais ou menos responsividade a tipos diferentes de intervenção.

Mais adiante, Vazquez et al. (2021); Wilson et al. (2011) demonstra que existem diferentes **custos associados a cada tipo de intervenção** e **diferentes capacidades** (q). Além disso, mostram que normalmente há um **orçamento total disponível** (B), especialmente em países em desenvolvimento, motivando a busca de intervenções e alocações com alto custo-benefício. Por fim, o custo pode ser dividido entre **custos fixos** (cf) (treinamento, desenvolvimento de material, aquisição de sistemas, contratação inicial) e **custos variáveis** (cv) (material por aluno, horas de monitoria por aluno, nível de bolsa auxílio, transporte) (Abdul Latif Jameel Poverty Action Lab, 2014; Carter et al., 2023).

Por fim, Wilson et al. (2011); Freeman and Simonsen (2015); Vasconcelos et al. (2023); Eslamian et al. (2023) apontam que o **objetivo principal na literatura é reduzir o risco de evasão escolar**, mas que ainda é necessário aumentar o entendimento da relação entre múltiplas intervenções aplicadas em conjunto, justificando a utilização de métodos de Programação Linear Inteira.

O problema pode ser definido da seguinte forma:

Entrada:

Uma tupla $\langle A, I, S, r, cv, cf, e, B, q \rangle$, onde:

- $A = \{1, \dots, n\}$ é um conjunto de alunos (estudantes matriculados);
- $I = \{1, \dots, m\}$ é um conjunto de tipos de intervenções disponíveis (ex: bolsa auxílio, transporte escolar, reforço pedagógico, merenda reforçada);
- $S = \{S_{a_j} : a_j \in A\}$ é a coleção de subconjuntos de intervenções que podem ser aplicadas a um aluno a_j , onde cada $S_{a_j} \subseteq I$. S_{a_j} não contém necessariamente todos os subconjuntos de I , mas apenas aqueles que fazem sentido aplicar em conjunto ao aluno a_j ;
- r é uma função $r : A \rightarrow [0, 1]$ que associa a cada aluno um risco inicial de evasão;
- cv é uma função $cv : I \times A \rightarrow \mathbb{R}^+$ que associa um custo variável de aplicar uma intervenção i_i a um aluno a_j ;
- cf é uma função $cf : I \rightarrow \mathbb{R}^+$ que associa a cada tipo de intervenção um custo fixo de implementação;
- e é uma função $e : \{(s_k, a_j) : s_k \in S_{a_j}, a_j \in A\} \rightarrow [0, 1]$ que representa a efetividade esperada de aplicar o conjunto de intervenções s_k ao aluno a_j (redução no risco de evasão);
- B é o orçamento total disponível (valor não negativo);
- q é uma função $q : I \rightarrow \mathbb{N}$ que define a capacidade máxima de atendimento q_i para cada tipo de intervenção;

Solução:

Uma atribuição $X \subseteq A \times I$ que especifica quais alunos receberão quais intervenções, tal que:

- O custo total não exceda o orçamento: $\sum_{(i_i, a_j) \in X} cv(i_i, a_j) + \sum_{i_i \in I} cf(i_i) \leq B$
- As capacidades sejam respeitadas: para cada $i_i \in I$, $|\{a_j : (i_i, a_j) \in X\}| \leq q(i_i)$

Objetivo:

Minimizar o risco total agregado de evasão após as intervenções:

$$\min_{a_j \in A} \sum r(a_j) \cdot (1 - e(a_j, \bigcup_{(i, a_j) \in X} i))$$

5. Resultados Preliminares

5.1 NP-dificuldade

Reduziremos o Problema da Cobertura Exata por 3-Conjuntos (Exact Cover by 3-Sets), que é conhecido por ser NP-difícil (Karp, 1972; Garey and Johnson, 1979), para o PEE.

Definição do Problema da Cobertura Exata por 3-Conjuntos (X3C)

Entrada: Uma tupla $\langle U, C \rangle$, onde:

- $U = \{u_1, u_2, \dots, u_j\}$ é um conjunto de $3m$ elementos;
- $C = \{S_1, S_2, \dots, S_i\}$ é uma coleção de subconjuntos de U , onde para cada $S_i \in C$, $|S_i| = 3$;

Objetivo: Existe $C' \subseteq C$ tal que todo elemento de U aparece em exatamente um conjunto de C' ?

Teorema: O Problema da Evasão Escolar (PEE) é NP-difícil.

Prova: Dado uma instância $\varphi = \langle U, C \rangle$ de X3C, construímos uma instância $\psi = \langle A, I, S', r, cv, cf, e, B, q \rangle$ do PEE da seguinte forma:

- Conjunto de Alunos (A): Para cada elemento $u_j \in U$, criamos um aluno $a_j \in A$. Portanto, $|A| = 3m$
- Conjunto de Intervenções (I): Para cada subconjunto $S_i \in C$, criamos uma intervenção $i_i \in I$. Logo, $|I| = |C|$.
- Subconjuntos de Intervenções (S_{a_j}): Para cada aluno a_j correspondente ao elemento u_j , $S_{a_j} = \{\{i_i\} : u_j \in S_i\} \cup \{\emptyset\}$

- Função de Risco Inicial ($r(a_j)$): Para cada aluno $a_j \in A$, definimos $r(a_j) = 1$
- Função de Custo Variável ($cv(i_i, a_j)$): Para cada aluno a_j e intervenção i_i , definimos $cv(i_i, a_j) = 0$.
- Função de Custo Fixo ($cf(i_i)$): Para cada intervenção $i_i \in I$, definimos $cf(i_i) = 1$.
- Função de Efetividade ($e(s_k, a_j)$): Para cada aluno a_j e conjunto de intervenções $s_k \in S_{a_j}$:

$$e(s_k, a_j) = \begin{cases} 1 & \text{se } |s_k| = 1 \\ 0 & \text{caso contrário} \end{cases}$$

Ou seja, a efetividade é total se e somente se o aluno recebe uma intervenção.

- Capacidade (q): Para cada intervenção i_i correspondente ao conjunto S_i , definimos $q(i_i) = 3$, ou seja, cada intervenção pode atender até 3 alunos.
- Orçamento (B): $B = m$

Vamos mostrar que se existe cobertura exata C' para X3C, então existe solução ótima para PEE com risco zero.

Seja $C' = \{S_1, S_2, \dots, S_m\}$ uma cobertura exata de U . Construímos $X \subseteq A \times I$ onde para cada conjunto $S_i \in C'$ e cada elemento $u_j \in S_i$, incluímos (a_j, i_i) em X . Para o orçamento, como $|C'| = m$ e a ativação de cada intervenção tem custo 1, temos que o custo total é $1 \times m = m = B$. Para a capacidade, como cada intervenção i_i atende exatamente 3 alunos correspondentes aos 3 elementos de S_i , portanto $|\{a_j : (a_j, i_i) \in X\}| = 3 \leq q(i_i)$. Por fim, como C' é uma cobertura exata, todo aluno a_j recebe exatamente uma intervenção, logo $e(s_k, a_j) = 1$ para todo a_j e o risco total é zero.

Para a outra direção, suponha que existe uma solução X para PEE com risco total zero, logo cada aluno está coberto por exatamente uma intervenção i_i , uma vez que isso é necessário para $e(s_k, a_j) = 1$. Seja $I' = \{i_i \in I : \exists a_j \text{ tal que } (a_j, i_i) \in X\}$ o conjunto de intervenções utilizadas. O custo total da solução é dado por $\sum_{i_i \in I'} cf(i_i) = |I'| \times 1$. Como o custo não pode exceder $B = m$, temos que $|I'| \times 1 \leq m$, logo $|I'| \leq m$. Por outro lado, cada intervenção em I' atende no máximo $q(i_i) = 3$ alunos, de modo que o total de alunos atendidos é no máximo $|I'| \times 3$. Como todo aluno recebe uma intervenção, todos os $3m$ alunos são atendidos. Assim, segue que $|I'| \times 3 \geq 3m$, e portanto $|I'| \geq m$. Combinando as duas desigualdades, concluímos que $|I'| = m$, ou seja, exatamente m intervenções são ativadas. Por fim, definimos $C' = \{S_i : i_i \in I'\}$, que é uma cobertura exata de U .

A redução pode ser computada em tempo polinomial, dado que criar A requer $O(m)$ operações, criar I requer $O(|C|)$, criar S_{a_j} requer $O(m \cdot |C|)$ e definir as funções requer $O(1)$. Como X3C é NP-difícil e reduzimos em tempo polinomial para PEE, concluímos que PEE é NP-difícil.

5.2 Formulação Matemática

Parâmetros e Conjuntos:

- $A = \{1, \dots, n\}$: Conjunto de estudantes a
 $I = \{1, \dots, m\}$: Conjunto de intervenções i
 $S = \{S_a : a \in A\}$: Coleção de subconjuntos de intervenções S_a que podem ser aplicadas ao aluno a
 $r_a \in [0, 1]$: Risco inicial de evasão do aluno $a \in A$
 $cv_{i,a} \in \mathbb{R}^+$: Custo variável da intervenção $i \in I$ aplicada ao aluno $a \in A$
 $cf_i \in \mathbb{R}^+$: Custo fixo de implementar a intervenção $i \in I$
 $e_{s,a} \in [0, 1]$: Efetividade de aplicar o conjunto de intervenções $s \in S_a$ ao aluno a
 B : Orçamento total disponível
 q_i : Capacidade máxima da intervenção i

Variáveis:

- $x_{i,a} \in \{0, 1\}$: Indica se o aluno a recebe a intervenção i
 $y_{s,a} \in \{0, 1\}$: Indica se o aluno a recebe o conjunto de intervenções $s \in S_a$
 $z_i \in \{0, 1\}$: Indica se a intervenção $i \in I$ foi acionada

Função Objetivo:

$$\min \sum_{a \in A} \sum_{s \in S_a} r_a \cdot (1 - e_{s,a}) \cdot y_{s,a} \quad (1)$$

Restrições:

$$\sum_{a \in A} \sum_{i \in I} cv_{i,a} x_{i,a} + \sum_{i \in I} cf_i z_i \leq B \quad (\text{Orçamento}) \quad (2)$$

$$\sum_{a \in A} x_{i,a} \leq q_i \quad \forall i \in I \quad (\text{Capacidade}) \quad (3)$$

$$\sum_{s \in S_a} y_{s,a} = 1 \quad \forall a \in A \quad (\text{Seleção de Subconjuntos}) \quad (4)$$

$$x_{i,a} = \sum_{s \in S_a : i \in s} y_{s,a} \quad \forall a \in A, \forall i \in I \quad (\text{Consistência}) \quad (5)$$

$$x_{i,a} \leq z_i \quad \forall a \in A, \forall i \in I \quad (\text{Ativação de intervenções}) \quad (6)$$

$$x_{i,a}, y_{s,a}, z_i \in \{0, 1\} \quad \forall a \in A, \forall i \in I \quad (\text{Domínio das Variáveis}) \quad (7)$$

6. Plano de Trabalho e Cronograma

Table 1: Cronograma de atividades

Atividade	T1 2025 Mar	T2 2025 Abr-Jun	T3 2025 Jul-Set	T4 2025 Out-Dez	T5 2026 Jan-Mar	T6 2026 Abr-Jun	T7 2026 Jul-Set	T8 2026 Out-Dez
Formação Acadêmica								
Cumprimento de carga horária	•	•	•	•				
Desenvolvimento da Pesquisa								
Revisão bibliográfica		•	•	•				
Coleta e tratamento de dados						•		
Modelagem preditiva						•		
Modelagem de otimização						•	•	
Validação e simulação							•	
Produção Científica e Defesa								
Redação da dissertação			•	•	•	•	•	•
Exame de qualificação				•				
Submissão de artigo(s)							•	•
Preparação para defesa							•	•
Defesa da dissertação								•

Referências Bibliográficas

- Abdul Latif Jameel Poverty Action Lab (2014). Costing guidelines: Collecting detailed cost data to improve the policy relevance of education evaluations. Technical report, J-PAL. Acesso em: 13 set. 2025.
- Banguiao, S. G. and Galigao, R. (2025). Economic bearing of school dropouts on human capital. *Pantao (International Journal of the Humanities and Social Sciences)*.
- Camargos, R. C. and Silveira, I. F. (2025). Mitigating cognitive biases in predicting student dropout: Global and local explainability with explainable boosting machine. *Journal of Universal Computer Science*, 31(10):1017–1041.
- Carter, S., Dathan, A., Murphy, K., and Tangoren, C. (2023). Using cost-effectiveness analysis to inform decision-making: Applications in the education sector. In Rangarajan, A., editor, *The Oxford Handbook of Program Design and Implementation Evaluation*, chapter 23, pages 468–485. Oxford University Press.
- Cataldo, A., Ferrer, J.-C., Miranda, J., Rey, P. A., and Sauré, A. (2017). An integer programming approach to curriculum-based examination timetabling. *Annals of Operations Research*, 258(2):369–393.
- Cobacho, B., Caballero, R., González, M., and Molina, J. (2010). Planning federal public investment in mexico using multiobjective decision making. *Journal of the Operational Research Society*, 61(9):1328–1339.
- Colpo, M. (2021). Predição da evasão estudantil: uma análise comparativa de diferentes representações de treino na aprendizagem de modelos genéricos. In *Anais do XXXII*

- Simpósio Brasileiro de Informática na Educação*, pages 873–884, Porto Alegre, RS, Brasil. SBC.
- Dragone, D., Migali, G., and Zucchelli, E. (2021). High school dropout and the intergenerational transmission of crime. IZA Discussion Paper 14129, IZA –Institute of Labor Economics.
- Eslamian, A., Arshi, M., Tahmasebi, S., Alipour, F., and Rafey, H. (2023). Scoping Review on Interventions, Actions, and Policies Affecting Return to School and Preventing School Dropout in Primary School. *International Journal of Preventive Medicine*, 14(92).
- Eurostat (2024). Glossary: Early leaver from education and training. Statistics Explained [online]. Define indivíduo de 18–24 anos com nível máximo de educação secundária inferior e sem educação ou formação recente; dados de 2024.
- Freeman, J. and Simonsen, B. (2015). Examining the Impact of Policy and Practice Interventions on High School Dropout and School Completion Rates: A Systematic Review of the Literature. *Review of Educational Research*, 85(2):205–248.
- Garey, M. R. and Johnson, D. S. (1979). *Computers and Intractability: A Guide to the Theory of NP-Completeness*. W. H. Freeman and Company, New York.
- INEP (2023). Censo escolar da educação básica: Resumo técnico. Technical report, Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira.
- INEP (2025). Microdados do censo escolar da educação básica. <https://www.gov.br/inep/pt-br/aceso-a-informacao/dados-abertos/microdados/censo-escolar>. Atualizado em 09/04/2025.
- Johnes, J. (2015). Operational research in education. *European Journal of Operational Research*, 243(3):683–696.
- Karp, R. M. (1972). Reducibility among combinatorial problems. In Miller, R. E. and Thatcher, J. W., editors, *Complexity of Computer Computations*, The IBM Research Symposia Series, pages 85–103. Plenum Press, New York.
- Levin, H., Belfield, C., Muennig, P., and Rouse, C. (2007). The costs and benefits of an excellent education for all of america’s children.
- Liu, H., Mao, M., Li, X., and Gao, J. (2025). Model interpretability on private-safe oriented student dropout prediction. *PLOS ONE*, 20(3):e0317726.
- Marius Profiroiu, C., Cibu, B., Delcea, C., and Cotfas, L.-A. (2024). Charting the course of school dropout research: A bibliometric exploration. *IEEE Access*, 12:71453–71478.
- Ministério da Educação (Brasil) (2021). Portaria nº 177, de 30 de março de 2021: Institui o programa brasil na escola. Diário Oficial da União, Seção 1, No. 61, de 31 de março de 2021.

- National Center for Education Statistics (NCES) (2019). Trends in high school dropout and completion rates in the united states. Inclui definições como “event dropout rate”; acesso à seção “Indicators”no site do NCES.
- Paes de Barros, R., Machado, L. M., Franco, S., Zanon, D., and Rocha, G. (2021). *Consequências da violação do direito à educação*. Autografia Editora.
- Pellegrini, M., Pannone, C., Fadda, D., Scalas, L. F., Vivanet, G., and Neitzel, A. J. (2025). Protocol: Prevention, intervention, and compensation programs to tackle school dropout: An evidence and gap map. *Campbell Systematic Reviews*, 21.
- Petropoulos, F., Laporte, G., Aktas, E., Alumur, S. A., Archetti, C., Ayhan, H., Battarra, M., Bennell, J. A., Bourjolly, J.-M., Boylan, J. E., Breton, M., Canca, D., Charlin, L., Chen, B., Cicek, C. T., Jr., L. A. C., Currie, C. S. M., Demeulemeester, E., Ding, L., Disney, S. M., Ehrgott, M., Eppler, M. J., Erdoğan, G., Fortz, B., Franco, L. A., Frische, J., Greco, S., Gregory, A. J., Hämäläinen, R. P., Herroelen, W., Hewitt, M., Holmström, J., Hooker, J. N., Işık, T., Johnes, J., Kara, B. Y., Özlem Karsu, Kent, K., Köhler, C., Kunc, M., Kuo, Y.-H., Letchford, A. N., Leung, J., Li, D., Li, H., Lienert, J., Ljubić, I., Lodi, A., Lozano, S., Lurkin, V., Martello, S., McHale, I. G., Midgley, G., Morecroft, J. D. W., Mutha, A., Oğuz, C., Petrovic, S., Pferschy, U., Psaraftis, H. N., Rose, S., Saarinen, L., Salhi, S., Song, J.-S., Sotiros, D., Stecké, K. E., Strauss, A. K., İstenç Tarhan, Thielen, C., Toth, P., Woensel, T. V., Berghe, G. V., Vasilakis, C., Vaze, V., Vigo, D., Virtanen, K., Wang, X., Weron, R., White, L., Yearworth, M., Yıldırım, E. A., Zaccour, G., and Zhao, X. (2024). Operational research: Methods and applications. *Journal of the Operational Research Society*, 75(3):423–617.
- Qu, R., Pham, N., Bai, R., and Kendall, G. (2015). Hybridising heuristics within an estimation distribution algorithm for examination timetabling. *Applied Intelligence*, 42(4):679–693.
- Quimiz-Moreira, M., Delgadillo, R., Parraga-Alava, J., Maculan, N., and Mauricio, D. (2025). Factors, prediction, explainability, and simulating university dropout through machine learning: A systematic review, 2012–2024. *Computation*, 13(8):198.
- Romero, S. and Liao, X. (2025). Statistical and machine learning models for predicting university dropout and scholarship impact. *PLOS ONE*, 20(6):e0325047.
- Sauvageot, C. (1996). *Indicators for Educational Planning: A Practical Guide*. UNESCO International Institute for Educational Planning (IIEP), Paris. 61 p.; segunda edição colaborativa com Nicole Bella, março de 2003.
- Seo, E.-Y., Yang, J., Lee, J.-E., and So, G. (2024). Predictive modelling of student dropout risk: Practical insights from a south korean distance university. Available at SSRN: <https://ssrn.com/abstract=4749857> or <http://dx.doi.org/10.2139/ssrn.4749857>.
- Silva, P. M. d. A., Ramos, G. C., and Furtado, D. C. M. S. (2023). Previsão da evasão escolar através da análise de dados e aprendizagem de máquina: Um estudo de caso. In *Anais do Workshop de Aplicações Práticas de Linguagens de Programação (WAPLA)*, volume 11, pages 19–30. Sociedade Brasileira de Computação.

- Vasconcelos, A. N. d., Freires, L. A., Loureto, G. D. L., Fortes, G., Costa, J. C. A. d., Torres, L. F. F., Bittencourt, I. I., Cordeiro, T. D., and Isotani, S. (2023). Advancing school dropout early warning systems: the IAFREE relational model for identifying at-risk students. *Frontiers in Psychology*, 14:1–17.
- Vazquez, E., Haimovich, F., and Adelman, M. (2021). Scalable Early Warning Systems for School Dropout Prevention: Evidence from a 4,000-School Randomized Controlled Trial. Technical Report 9685, World Bank, Washington, DC.
- Villar, A. and de Andrade, C. R. V. (2024). Supervised machine learning algorithms for predicting student dropout and academic success: a comparative study. *Discover Artificial Intelligence*, 4(1).
- Wilson, S. J., Tanner-Smith, E. E., Lipsey, M. W., Steinka-Fry, K., and Morrison, J. (2011). Dropout Prevention and Intervention Programs: Effects on School Completion and Dropout among School-aged Children and Youth. Technical Report 8, Campbell Systematic Reviews (John Wiley Sons).