



Universidade Estadual de Campinas (UNICAMP)
Instituto de Computação (IC)
Programa de Pós-Graduação em Ciência da Computação

Carlos Eduardo Cavalieri Furtado

Predição e Otimização de Intervenções para Redução da Evasão Escolar no
Brasil

CAMPINAS
1994

Carlos Eduardo Cavalieri Furtado

Predição e Otimização de Intervenções para Redução da Evasão Escolar no Brasil

Dissertação apresentada ao Instituto de Computação da Universidade Estadual de Campinas (UNICAMP) como parte dos requisitos exigidos para a obtenção do título de Mestre em Ciência da Computação.

Dissertation presented to the Institute of Computing of the University of Campinas (UNICAMP) in partial fulfillment of the requirements for the degree of Master in Computer Science.

Orientador: Prof. Dr. Santiago Valdés Ravelo

Este exemplar corresponde à versão da dissertação entregue à banca antes da defesa.

Na versão final esta página será substituída pela ficha catalográfica.

De acordo com o padrão da CCPG: “Quando se tratar de Teses e Dissertações financiadas por agências de fomento, os beneficiados deverão inserir no formulário de solicitação da ficha catalográfica as informações sobre agência e número do processo pelo qual receberam o auxílio, porém essa informação não ficará visível na ficha, será utilizada para fins estatísticos. Os auxílios recebidos devem também ser citados na seção “Agradecimento” seguindo os padrões exigidos pelas agências de fomento.”

e

“caso a tese de doutorado seja feita em Cotutela, será necessário informar na ficha catalográfica o fato, a Universidade conveniente, o país e o nome do orientador.”

Na versão final, esta página será substituída por outra informando a data da defesa e a composição da banca.

Agradecimentos

Os agradecimentos devem ocupar uma única página.

Resumo

O resumo deve ter no máximo 500 palavras e deve ocupar uma única página.

Abstract

A mesma regra do resumo aplica-se.

Lista de Figuras

Lista de Tabelas

Sumário

1	Introdução	11
1.1	Objetivos e Hipóteses	12
1.2	Contribuições	14
1.3	Organização do Texto	15
2	Conceitos Preliminares	16
3	Revisão da Literatura	17
4	Materiais e Métodos	18
4.1	Base de Dados	18
5	Resultados e Discussão	19
5.1	Formalização e Complexidade do PEE	19
5.2	Resultados Experimentais	19
6	Conclusão e Trabalho Futuro	20
	Referências Bibliográficas	21
	Apêndice A Capítulo 1 anexo 1	23
A.1	Capítulo 1 anexo 1 seção 1	23
A.2	Capítulo 1 anexo 1 seção 2	23

Capítulo 1

Introdução

A Evasão Escolar (EE) constitui um dos desafios mais persistentes da educação básica brasileira. De acordo com o Ministério da Educação (MEC), esse fenômeno é caracterizado quando um aluno regularmente matriculado em um ano letivo não retorna para a escola no ano seguinte [2]. Somente entre 2021 e 2022, dados publicados pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP) apontam que aproximadamente 1,3 milhões de alunos do ensino básico regular evadiram a escola, número que representa 3,2% do total de matrículas [8].

Caracterizada por um fenômeno complexo e multidimensional, a EE resulta de um desengajamento prolongado e não de uma decisão súbita causada por fatores recentes e temporários [6, 18, 7]. As principais causas podem ser categorizadas em quatro níveis sistêmicos: (i) individual, como reprovação, absenteísmo e defasagem série-idade; (ii) familiar, como nível socioeconômico, responsabilidades domésticas e ausência parental; (iii) escolar, como infraestrutura escolar, tamanho das turmas e dependência administrativa (pública ou privada); (iv) comunitário, como distância da escola, urbanização e segurança [13].

Como consequência, abandonar a escola precocemente tem impactos negativos diversos a nível individual. Do ponto de vista econômico, a evasão está associada com uma probabilidade significativamente maior de desemprego e ocupação de vagas que exigem pouca qualificação, resultando em salários substancialmente menores ao longo de suas vidas profissionais [18]. No âmbito de saúde, a EE também está ligada a problemas de saúde física e mental e a uma menor expectativa de vida, enquanto no contexto socio-comportamental o abandono escolar indica aumento da probabilidade de envolvimento em atividades criminosas e de encarceramento [18].

Por outro lado, os impactos da evasão também são reconhecidos em escala macroeconômica. A sociedade perde quantias consideráveis em arrecadação de impostos devido à baixa renda desses indivíduos, ao mesmo tempo que os governos sofrem um aumento nos gastos com saúde pública, assistência social e manutenção do sistema prisional e judicial [10, 3]. Paes de Barros et al. (2021) [3] estimam que o custo para a sociedade por jovem que não conclui a educação básica no Brasil é de R\$395 mil.

Dado o tamanho e gravidade do impacto da EE, diversos governos e unidades administrativas têm investido no desenvolvimento de Sistemas de Alerta Preventivos (EWS - *Early Warning Systems*) [4], frequentemente suportados pela utilização de modelos pre-

ditivos de Aprendizado de Máquina (ML - *Machine Learning*). São utilizadas desde técnicas clássicas, como *Random Forest*, Regressão Logística, *Support Vector Machines* (SVM), Árvores de Decisão e *K-Nearest Neighbors* (KNN) [5, 11], até o uso de Redes Neurais e *Deep Learning*, como redes *Long Short-Term Memory* (LSTM) e *Convolutional Neural Network* (CNN) [1, 19]. Mais adiante, como modelos muito complexos agem como “caixas-pretas” difíceis de interpretar, tem havido um esforço crescente para usar técnicas de IA Explicável (como SHAP e SAGE). Em vez de apenas gerar uma lista de quem vai evadir, esses sistemas mostram aos professores e gestores os principais atributos considerados na estimativa do risco de evasão, permitindo o desenvolvimento de políticas de mitigação, garantias de equidade e transparência [17, 14].

Há um movimento crescente e estruturado na literatura atual rumo à análise prescritiva, deslocando o foco de quem irá evadir para o que fazer a respeito. Esse movimento apoia-se em métodos de inferência causal, que buscam estimar não apenas o risco inicial de evasão, mas a redução esperada nesse risco decorrente da aplicação de uma intervenção a um aluno. Tais estimativas derivam, em grande parte, de estudos experimentais e quase-experimentais, que constituem a principal fonte de evidência sobre a efetividade de intervenções educacionais [15, 7, 20]

Contudo, as abordagens prescritivas permanece aquém do problema enfrentado na prática por gestores educacionais. A literatura mostra que, apesar de reconhecida a necessidade de tratar múltiplos fatores de risco em conjunto, a maior parte da produção científica avalia uma única intervenção por vez, aplicada a indivíduos ou pequenos grupos [7, 20]. O esforço se concentra em medir o impacto de um programa isolado, e não em otimizar a alocação de um conjunto de intervenções sobre uma população estudantil heterogênea e sob restrições orçamentárias e de capacidade.

Decisões dessa natureza constituem o objeto clássico da Pesquisa Operacional (PO), amplamente aplicada a problemas educacionais similares, como a alocação de professores, turmas e infraestrutura entre escolas [9, 12, 16]. No entanto, até onde nossa revisão da literatura identificou, o problema da evasão escolar ainda não foi formalizado como um problema de otimização combinatória e as ferramentas de PO ainda não foram aplicadas para solucioná-lo.

1.1 Objetivos e Hipóteses

O objetivo geral deste trabalho é formalizar o Problema da Evasão Escolar (PEE) como um problema de otimização combinatória de alocação de intervenções preventivas sob restrições de orçamento e capacidade, caracterizar sua complexidade computacional e desenvolver métodos de solução exatos e heurísticos capazes de produzir alocações de alta qualidade em escala compatível com redes escolares brasileiras reais. As intervenções são consideradas predominantemente no nível de escolas e turmas, em consonância com as características estruturais disponíveis nos dados educacionais brasileiros, sendo a alocação individual tratada como caso particular da mesma formulação. O modelo recebe como entrada o risco inicial de evasão de cada aluno, estimado por modelos de aprendizado de máquina, e a efetividade esperada de cada intervenção, calibrada a partir da literatura e

submetida a análise de sensibilidade.

Para alcançar esse objetivo geral, definem-se os seguintes objetivos específicos:

1. Definir formalmente o PEE, especificando entrada, solução e função objetivo, de modo a capturar a alocação de múltiplos tipos de intervenção sobre uma população estudantil heterogênea sob restrições orçamentárias e de capacidade.
2. Caracterizar a complexidade computacional do PEE, estabelecendo sua NP-dificuldade.
3. Propor uma formulação de Programação Linear Inteira (PLI) para o PEE, bem como variantes relevantes do problema, incluindo formulações por escola, por turma e com restrições de equidade.
4. Avaliar a resolução exata do modelo por meio de *solvers* de otimização, definindo o limite prático de escalabilidade da abordagem exata.
5. Desenvolver e avaliar métodos heurísticos e meta-heurísticos que produzam soluções de qualidade comparável à exata em tempo menor, viabilizando instâncias de grande porte.
6. Estimar o risco inicial de evasão por meio de modelos de aprendizado de máquina, comparando modelos diretamente interpretáveis e modelos de maior complexidade aliados a técnicas de explicabilidade.
7. Definir os parâmetros de efetividade das intervenções a partir de estimativas reportadas na literatura de avaliação de intervenções educacionais, tratando-os como entrada do modelo de otimização e caracterizando, por meio de análise de sensibilidade, como a solução ótima e a redução de evasão respondem à variação desses parâmetros dentro de faixas plausíveis.
8. Validar a abordagem por meio de estudo computacional sobre os microdados do Censo Escolar do INEP, avaliando o desempenho dos métodos propostos, a magnitude da redução de evasão alcançável sob diferentes cenários orçamentários e de capacidade, e a robustez das soluções frente à variação dos parâmetros de entrada.

A partir dos objetivos citados, este trabalho orienta-se pelas seguintes hipóteses de pesquisa, que serão verificadas ao longo do estudo computacional:

- H1: Por ser NP-difícil, o PEE não admite solução exata em tempo computacional viável para instâncias de porte estadual ou nacional. A abordagem exata, baseada em *solvers* de otimização, atinge um limite prático de escalabilidade a partir do qual o tempo de resolução se torna proibitivo, o que justifica o desenvolvimento de métodos heurísticos.
- H2: A formulação do PEE como otimização combinatória conjunta sobre o conjunto de intervenções, sob restrições de orçamento e capacidade, produz maior redução agregada do risco de evasão do que as estratégias predominantes na literatura, como a alocação de uma única intervenção predefinida e a priorização gulosa dos alunos de maior risco inicial.

- H3: Sob restrição orçamentária, a alocação orientada pela efetividade esperada das intervenções produz maior redução agregada de evasão do que a alocação orientada apenas pelo risco inicial, uma vez que risco e responsividade à intervenção não são necessariamente correlacionados. Esta hipótese é avaliada por meio de análise de sensibilidade sobre os parâmetros de efetividade, sem depender de sua estimação causal a partir dos dados.
- H4: Métodos heurísticos e meta-heurísticos projetados para o PEE produzem soluções com gap de otimalidade reduzido em relação à solução exata, em tempo significativamente menor, viabilizando a resolução de instâncias para as quais a abordagem exata é inviável.
- H5: A incorporação de restrições de equidade à formulação, definidas sobre dimensões observáveis no nível de escola, como região e contexto socioeconômico do território, implica perda de eficiência agregada limitada e quantificável, de modo que ganhos de equidade na alocação podem ser obtidos mediante redução controlada da redução total de evasão.

1.2 Contribuições

As principais contribuições deste trabalho situam-se na interseção entre Aprendizado de Máquina, Inferência Causal e Pesquisa Operacional, e podem ser resumidas da seguinte forma:

1. A formalização do PEE como um problema de otimização combinatória. Até onde a revisão sistemática da literatura conduzida neste trabalho identificou, a evasão escolar ainda não havia sido tratada formalmente como um problema de alocação ótima de intervenções, de modo que a definição aqui proposta constitui contribuição inédita.
2. A demonstração de que o PEE é NP-difícil, obtida por redução a partir do Problema da Cobertura Exata por 3-Conjuntos. Esse resultado fundamenta teoricamente a intratabilidade do problema em escala realista e justifica o desenvolvimento de métodos heurísticos.
3. Uma formulação de Programação Linear Inteira para o PEE, acompanhada de variantes que incorporam restrições operacionais e de equidade, ampliando a aplicabilidade do modelo a diferentes contextos de gestão educacional.
4. O desenvolvimento de métodos heurísticos e meta-heurísticos que tornam o problema tratável em instâncias de porte estadual e nacional, para as quais a resolução exata se mostra computacionalmente proibitiva.
5. A integração explícita entre risco de evasão e efetividade das intervenções no critério de alocação. Ao deslocar a decisão do risco inicial para a redução esperada de risco, o trabalho conecta as etapas de predição e prescrição, que na literatura permanecem

tratadas de maneira isolada, e estabelece, por meio da análise de sensibilidade, em que condições essa distinção altera a alocação ótima.

6. Um estudo computacional conduzido sobre os microdados do Censo Escolar do INEP, no qual se avalia o desempenho dos métodos propostos, a magnitude da redução de evasão alcançável sob diferentes cenários orçamentários e de capacidade, e a robustez das soluções por meio de análise de sensibilidade sobre os parâmetros de efetividade.

1.3 Organização do Texto

O restante deste texto está organizado em cinco capítulos. O Capítulo 2 apresenta os conceitos preliminares necessários à compreensão do trabalho, abrangendo as definições e a notação relativas à evasão escolar, à otimização combinatória e à Programação Linear Inteira, à teoria de complexidade computacional e aos fundamentos de aprendizado de máquina utilizados na estimação do risco inicial de evasão.

O Capítulo 3 revisa a literatura relacionada, organizada em três frentes: os modelos preditivos de risco de evasão e as técnicas de explicabilidade associadas; as abordagens prescritivas voltadas à avaliação e à alocação de intervenções, fundamentadas na inferência causal e apoiadas sobretudo em estudos experimentais e quase-experimentais; e as aplicações de Pesquisa Operacional a problemas de planejamento e alocação de recursos no contexto educacional.

O Capítulo 4 descreve os materiais e métodos. Apresenta os microdados do Censo Escolar do INEP e as características estruturais de escolas e turmas consideradas na definição das intervenções, detalha os modelos preditivos empregados na estimação do risco inicial, descreve a calibração dos parâmetros de efetividade a partir da literatura e especifica os métodos exatos e heurísticos adotados na resolução do problema de otimização, bem como o protocolo experimental e as métricas de avaliação.

O Capítulo 5 reúne os resultados e sua discussão. Inicia com as contribuições de natureza teórica, apresentando a definição formal do PEE, a demonstração de sua NP-dificuldade por redução a partir do Problema da Cobertura Exata por 3-Conjuntos e a formulação de Programação Linear Inteira proposta, juntamente com suas variantes operacionais e de equidade. Em seguida, expõe os resultados experimentais, incluindo a avaliação de desempenho dos métodos propostos, a magnitude da redução de evasão alcançável sob diferentes cenários orçamentários e de capacidade, e a análise de sensibilidade em relação à efetividade estimada. Os resultados são confrontados com as hipóteses de pesquisa enunciadas na Seção 1.1.

Por fim, o Capítulo 6 apresenta as conclusões do trabalho, retomando as contribuições, discutindo suas limitações e apontando direções para trabalhos futuros.

Capítulo 2

Conceitos Preliminares

Capítulo 3

Revisão da Literatura

Capítulo 4

Materiais e Métodos

4.1 Base de Dados

Capítulo 5

Resultados e Discussão

5.1 Formalização e Complexidade do PEE

5.2 Resultados Experimentais

Capítulo 6

Conclusão e Trabalho Futuro

Referências Bibliográficas

- [1] Houssam El Aouifi, Mohamed El Hajji, and Youssef Es-Saady. A hybrid approach for early-identification of at-risk dropout students using lstm-dnn networks. *Education and Information Technologies*, 29:18839–18857, 2024.
- [2] BRASIL. Ministério da Educação. Portaria nº 177, de 30 de março de 2021. *Diário Oficial da União*, (seção 1):171, 31 mar. 2021.
- [3] Ricardo Paes de Barros, Samuel Franco, Laura Muller Machado, Daiane Zanon, and Grazielly Rocha. *Consequências da violação do direito à educação*. Autografia, Rio de Janeiro, 2021.
- [4] Angelina Nunes de Vasconcelos, Leogildo Alves Freires, Gleidson Diego Lopes Loureto, Gabriel Fortes, Júlio Cezar Albuquerque da Costa, Luan Filipy Freire Torres, Ig Ibert Bittencourt, Thiago Damasceno Cordeiro, and Seiji Isotani. Advancing school dropout early warning systems: the iafree relational model for identifying at-risk students. *Frontiers in Psychology*, 14:1189283, 2023.
- [5] Marco Delogu, Raffaele Lagravinese, Dimitri Paolini, and Giuliano Resce. Predicting dropout from higher education: Evidence from italy. *Economic Modelling*, 130:106583, 2024.
- [6] Jeremy D. Finn. Withdrawing from school. *Review of Educational Research*, 59(2):117–142, 1989.
- [7] Jennifer Freeman and Brandi Simonsen. Examining the impact of policy and practice interventions on high school dropout and school completion rates: A systematic review of the literature. *Review of Educational Research*, 85(2):205–248, 2015.
- [8] Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira. Taxas de transição, 2020.
- [9] Jill Johnes. Operational research in education. *European Journal of Operational Research*, 243(3):683–696, 2015.
- [10] Henry M. Levin, Clive Belfield, Peter A. Muennig, and Cecilia Rouse. The costs and benefits of an excellent education for all of america’s children. Technical report, Teachers College, Columbia University, 2007.

- [11] Markson Rebelo Marcolino, Thiago Reis Porto, Tiago Thompsen Primo, Rafael Targino, Vinicius Ramos, Emanuel Marques Queiroga, Roberto Munoz, and Cristian Cechinel. Student dropout prediction through machine learning optimization: insights from moodle log data. *Scientific Reports*, 15(1):9840, 2025.
- [12] Sérgio F. Mayerle, H. F. Rodrigues, João Neiva de Figueiredo, and D. M. D. Chiroli. Optimal student/school/class/teacher/classroom matching to support efficient public school system resource allocation. *Socio-Economic Planning Sciences*, 83:101341, 2022.
- [13] Michelle S. M. Momo, Sofie J. Cabus, Kristof De Witte, and Wim Groot. A systematic review of the literature on the causes of early school leaving in africa and asia. *Review of Education*, 7(3):496–522, 2019.
- [14] Marcell Nagy and Roland Molontay. Interpretable dropout prediction: Towards xai-based personalized intervention. *International Journal of Artificial Intelligence in Education*, 34(2):274–300, 2024.
- [15] Diego Olaya, Jonathan Vásquez, Sebastián Maldonado, Jaime Miranda, and Wouter Verbeke. Uplift modeling for preventing student dropout in higher education. *Decision Support Systems*, 134:113320, 2020.
- [16] Fotios Petropoulos, Gilbert Laporte, Emel Aktas, et al. Operational research: methods and applications. *Journal of the Operational Research Society*, 75(3):423–617, 2024.
- [17] Goran Radić, Luka Jovanović, Nebojša Bačanin, Miloš S. Stanković, Vladimir Simić, Miloš Antonijević, et al. Identifying and understanding student dropouts using metaheuristic optimized classifiers and explainable artificial intelligence techniques. *IEEE Access*, 12:122377–122400, 2024.
- [18] Russell W. Rumberger. *Dropping Out: Why Students Drop Out of High School and What Can Be Done About It*. Harvard University Press, Cambridge, MA, 2011.
- [19] Hui Shi, Nuodi Zhang, Secil Caskurlu, and Hunhui Na. Applications of machine learning for at-risk student prediction in online education: A 10-year systematic review of literature. *Journal of Computer Assisted Learning*, 41(4):e70058, 2025.
- [20] Sandra J. Wilson, Mark W. Lipsey, Emily E. Tanner-Smith, C. H. Huang, and K. T. Steinka-Fry. Dropout prevention and intervention programs: Effects on school completion and dropout among school-aged children and youth: A systematic review. *Campbell Systematic Reviews*, 7(1):1–61, 2011.

Apêndice A

Capítulo 1 anexo 1

A.1 Capítulo 1 anexo 1 seção 1

A.2 Capítulo 1 anexo 1 seção 2