



Universidade Estadual de Campinas (UNICAMP)
Instituto de Computação (IC)
Programa de Pós-Graduação em Ciência da Computação

Carlos Eduardo Cavalieri Furtado

Predição e Otimização de Intervenções para Redução da Evasão Escolar no
Brasil

CAMPINAS
2026

Carlos Eduardo Cavalieri Furtado

Predição e Otimização de Intervenções para Redução da Evasão Escolar no Brasil

Dissertação apresentada ao Instituto de Computação da Universidade Estadual de Campinas (UNICAMP) como parte dos requisitos exigidos para a obtenção do título de Mestre em Ciência da Computação.

Dissertation presented to the Institute of Computing of the University of Campinas (UNICAMP) in partial fulfillment of the requirements for the degree of Master in Computer Science.

Orientador: Prof. Dr. Santiago Valdés Ravelo

Este exemplar corresponde à versão da dissertação entregue à banca antes da defesa.

Na versão final esta página será substituída pela ficha catalográfica.

De acordo com o padrão da CCPG: “Quando se tratar de Teses e Dissertações financiadas por agências de fomento, os beneficiados deverão inserir no formulário de solicitação da ficha catalográfica as informações sobre agência e número do processo pelo qual receberam o auxílio, porém essa informação não ficará visível na ficha, será utilizada para fins estatísticos. Os auxílios recebidos devem também ser citados na seção “Agradecimento” seguindo os padrões exigidos pelas agências de fomento.”

e

“caso a tese de doutorado seja feita em Cotutela, será necessário informar na ficha catalográfica o fato, a Universidade conveniente, o país e o nome do orientador.”

Na versão final, esta página será substituída por outra informando a data da defesa e a composição da banca.

Agradecimentos

Os agradecimentos devem ocupar uma única página.

Resumo

O resumo deve ter no máximo 500 palavras e deve ocupar uma única página.

Abstract

A mesma regra do resumo aplica-se.

Lista de Figuras

Lista de Tabelas

Sumário

1	Introdução	12
1.1	Objetivos e Hipóteses	13
1.2	Contribuições	15
1.3	Organização do Texto	16
2	Conceitos Preliminares	17
2.1	Evasão Escolar e Intervenções Preventivas	17
2.2	Aprendizado de Máquina	18
2.3	Otimização Combinatória, Complexidade e Métodos de Solução	19
3	Revisão da Literatura	22
3.1	Predição do Risco de Evasão e Explicabilidade	22
3.2	Da Predição à Prescrição: Inferência Causal e Efetividade das Intervenções	24
3.3	Pesquisa Operacional na Alocação de Recursos Educacionais	25
3.4	Síntese e Posicionamento da Pesquisa	27
4	Materiais e Métodos	28
4.1	Base de Dados	28
4.2	Estimativa do Risco Inicial	28
4.3	Construção das instâncias	28
4.3.1	Cálculo da efetividade	28
4.4	Métodos Exatos	28
4.5	Métodos Heurísticos	28
5	Resultados e Discussão	29
5.1	Formalização do PEE	29
5.2	Análise de Complexidade	31
5.3	Formulação como Programação Linear Inteira	32
5.4	Resultados Experimentais	35
6	Conclusão e Trabalho Futuro	36

Referências Bibliográficas	37
Apêndice A Capítulo 1 anexo 1	40
A.1 Capítulo 1 anexo 1 seção 1	40
A.2 Capítulo 1 anexo 1 seção 2	40

Capítulo 1

Introdução

A Evasão Escolar (EE) constitui um dos desafios mais persistentes da educação básica brasileira. De acordo com o Ministério da Educação (MEC), esse fenômeno é caracterizado quando um aluno regularmente matriculado em um ano letivo não retorna para a escola no ano seguinte [3]. Somente em 2022, dados publicados pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP) apontam que aproximadamente 1,3 milhões de alunos do ensino básico regular evadiram a escola, número que representa 3,2% do total de matrículas [11].

Caracterizada por um fenômeno complexo e multidimensional, a EE resulta de um desengajamento prolongado e não de uma decisão súbita causada por fatores recentes e temporários [8, 23, 9]. As principais causas podem ser categorizadas em quatro níveis sistêmicos: (i) individual, como reprovação, absenteísmo e defasagem série-idade; (ii) familiar, como nível socioeconômico, responsabilidades domésticas e ausência parental; (iii) escolar, como infraestrutura escolar, tamanho das turmas e dependência administrativa (pública ou privada); (iv) comunitário, como distância da escola, urbanização e segurança [18].

Como consequência, abandonar a escola precocemente tem impactos negativos diversos a nível individual. Do ponto de vista econômico, a evasão está associada com uma probabilidade significativamente maior de desemprego e ocupação de vagas que exigem pouca qualificação, resultando em salários substancialmente menores ao longo de suas vidas profissionais [23]. No âmbito de saúde, a EE também está ligada a problemas de saúde física e mental e a uma menor expectativa de vida, enquanto no contexto socio-comportamental o abandono escolar indica aumento da probabilidade de envolvimento em atividades criminosas e de encarceramento [23].

Por outro lado, os impactos da evasão também são reconhecidos em escala macroeconômica. A sociedade perde quantias consideráveis em arrecadação de impostos devido à baixa renda desses indivíduos, ao mesmo tempo que os governos sofrem um aumento nos gastos com saúde pública, assistência social e manutenção do sistema prisional e judicial [15, 5]. Paes de Barros et al. (2021) [5] estimam que o custo para a sociedade por jovem que não conclui a educação básica no Brasil é de R\$395 mil.

Dado o tamanho e gravidade do impacto da EE, diversos governos e unidades administrativas têm investido no desenvolvimento de Sistemas de Alerta Preventivos (EWS - *Early Warning Systems*) [6], frequentemente suportados pela utilização de modelos pre-

ditivos de Aprendizado de Máquina (ML - *Machine Learning*). São utilizadas desde técnicas clássicas, como *Random Forest*, Regressão Logística, *Support Vector Machines* (SVM), Árvores de Decisão e *K-Nearest Neighbors* (KNN) [7, 16], até o uso de Redes Neurais e *Deep Learning*, como redes *Long Short-Term Memory* (LSTM) e *Convolutional Neural Network* (CNN) [2, 24]. Mais adiante, como modelos muito complexos agem como “caixas-pretas” difíceis de interpretar, tem havido um esforço crescente para usar técnicas de IA Explicável (como SHAP e SAGE). Em vez de apenas gerar uma lista de quem vai evadir, esses sistemas mostram aos professores e gestores os principais atributos considerados na estimativa do risco de evasão, permitindo o desenvolvimento de políticas de mitigação, garantias de equidade e transparência [22, 19].

Há um movimento crescente e estruturado na literatura atual rumo à análise prescritiva, deslocando o foco de quem irá evadir para o que fazer a respeito. Esse movimento apoia-se em métodos de inferência causal, que buscam estimar não apenas o risco inicial de evasão, mas a redução esperada nesse risco decorrente da aplicação de uma intervenção a um aluno. Tais estimativas derivam, em grande parte, de estudos experimentais e quase-experimentais, que constituem a principal fonte de evidência sobre a efetividade de intervenções educacionais [20, 9, 26]

Contudo, as abordagens prescritivas permanece aquém do problema enfrentado na prática por gestores educacionais. A literatura mostra que, apesar de reconhecida a necessidade de tratar múltiplos fatores de risco em conjunto, a maior parte da produção científica avalia uma única intervenção por vez, aplicada a indivíduos ou pequenos grupos [9, 26]. O esforço se concentra em medir o impacto de um programa isolado, e não em otimizar a alocação de um conjunto de intervenções sobre uma população estudantil heterogênea e sob restrições orçamentárias, de capacidade e de equidade.

Decisões dessa natureza constituem o objeto clássico da Pesquisa Operacional (PO), amplamente aplicada a problemas educacionais similares, como a alocação de professores, turmas e infraestrutura entre escolas [12, 17, 21]. No entanto, até onde nossa revisão da literatura identificou, o problema da evasão escolar ainda não foi formalizado como um problema de otimização combinatória e as ferramentas de PO ainda não foram aplicadas para solucioná-lo.

1.1 Objetivos e Hipóteses

O objetivo geral deste trabalho é formalizar o Problema da Evasão Escolar (PEE) como um problema de otimização combinatória de alocação de intervenções preventivas sob restrições de orçamento, capacidade e equidade, caracterizar sua complexidade computacional e desenvolver métodos de solução exatos e heurísticos capazes de produzir alocações de alta qualidade em escala compatível com redes escolares brasileiras reais. As intervenções são consideradas predominantemente no nível de escolas e turmas, em consonância com as características estruturais disponíveis nos dados educacionais brasileiros, sendo a alocação individual tratada como caso particular da mesma formulação. O modelo recebe como entrada o risco inicial de evasão de cada aluno, estimado por modelos de aprendizado de máquina, e a efetividade esperada de cada intervenção, calibrada a partir da

literatura e submetida a análise de sensibilidade.

Para alcançar esse objetivo geral, definem-se os seguintes objetivos específicos:

1. Definir formalmente o PEE, especificando entrada, solução e função objetivo, de modo a capturar a alocação de múltiplos tipos de intervenção sobre uma população estudantil heterogênea sob restrições orçamentárias e de capacidade.
2. Caracterizar a complexidade computacional do PEE, estabelecendo sua NP-dificuldade.
3. Propor uma formulação de PLI para o PEE, incorporando restrições de equidade como parte central do modelo, e considerar variantes operacionais como formulações por escola e por turma.
4. Avaliar a resolução exata do modelo por meio de *solvers* de otimização, definindo o limite prático de escalabilidade da abordagem exata.
5. Desenvolver e avaliar métodos heurísticos e meta-heurísticos que produzam soluções de qualidade comparável à exata em tempo menor, viabilizando instâncias de grande porte.
6. Estimar o risco inicial de evasão por meio de modelos de aprendizado de máquina, comparando modelos diretamente interpretáveis e modelos de maior complexidade aliados a técnicas de explicabilidade.
7. Definir os parâmetros de efetividade das intervenções a partir de estimativas reportadas na literatura de avaliação de intervenções educacionais, tratando-os como entrada do modelo de otimização e caracterizando, por meio de análise de sensibilidade, como a solução ótima e a redução de evasão respondem à variação desses parâmetros dentro de faixas plausíveis.
8. Validar a abordagem por meio de estudo computacional sobre os microdados do Censo Escolar do INEP, avaliando o desempenho dos métodos propostos, a magnitude da redução de evasão alcançável sob diferentes cenários orçamentários e de capacidade, e a robustez das soluções frente à variação dos parâmetros de entrada.

A partir dos objetivos citados, este trabalho orienta-se pelas seguintes hipóteses de pesquisa, que serão verificadas ao longo do estudo computacional:

- H1: Por ser NP-difícil, o PEE não admite solução exata em tempo computacional viável para instâncias de porte estadual ou nacional. A abordagem exata, baseada em *solvers* de otimização, atinge um limite prático de escalabilidade a partir do qual o tempo de resolução se torna proibitivo, o que justifica o desenvolvimento de métodos heurísticos.
- H2: A formulação do PEE como otimização combinatória conjunta sobre o conjunto de intervenções, sob restrições de orçamento, capacidade e equidade, produz maior redução agregada do risco de evasão do que as estratégias predominantes na literatura, como a alocação de uma única intervenção predefinida e a priorização gulosa dos alunos de maior risco inicial.

- H3: Sob restrição orçamentária, a alocação orientada pela efetividade esperada das intervenções produz maior redução agregada de evasão do que a alocação orientada apenas pelo risco inicial, uma vez que risco e responsividade à intervenção não são necessariamente correlacionados. Esta hipótese é avaliada por meio de análise de sensibilidade sobre os parâmetros de efetividade, sem depender de sua estimação causal a partir dos dados.
- H4: Métodos heurísticos e meta-heurísticos projetados para o PEE produzem soluções com gap de otimalidade reduzido em relação à solução exata, em tempo significativamente menor, viabilizando a resolução de instâncias para as quais a abordagem exata é inviável.
- H5: A incorporação de restrições de equidade à formulação, definidas sobre dimensões observáveis no nível de escola, como região e contexto socioeconômico do território, implica perda de eficiência agregada limitada e quantificável, de modo que ganhos de equidade na alocação podem ser obtidos mediante redução controlada da redução total de evasão.

1.2 Contribuições

As principais contribuições deste trabalho situam-se na interseção entre Aprendizado de Máquina e Pesquisa Operacional, e podem ser resumidas da seguinte forma:

1. A formalização do PEE como um problema de otimização combinatória. Até onde a revisão sistemática da literatura conduzida neste trabalho identificou, a evasão escolar ainda não havia sido tratada formalmente como um problema de alocação ótima de intervenções, de modo que a definição aqui proposta constitui contribuição inédita.
2. A demonstração de que o PEE é NP-difícil, obtida por redução a partir do Problema da Cobertura Exata por 3-Conjuntos. Esse resultado fundamenta teoricamente a intratabilidade do problema em escala realista e justifica o desenvolvimento de métodos heurísticos.
3. Uma formulação de Programação Linear Inteira para o PEE, acompanhada de variantes que incorporam restrições operacionais e de equidade, ampliando a aplicabilidade do modelo a diferentes contextos de gestão educacional.
4. O desenvolvimento de métodos heurísticos e meta-heurísticos que tornam o problema tratável em instâncias de porte estadual e nacional, para as quais a resolução exata se mostra computacionalmente proibitiva.
5. A integração explícita entre risco de evasão e efetividade das intervenções no critério de alocação. Ao deslocar a decisão do risco inicial para a redução esperada de risco, o trabalho conecta as etapas de predição e prescrição, que na literatura permanecem tratadas de maneira isolada, e estabelece, por meio da análise de sensibilidade, em que condições essa distinção altera a alocação ótima.

6. Um estudo computacional conduzido sobre os microdados do Censo Escolar do INEP, no qual se avalia o desempenho dos métodos propostos, a magnitude da redução de evasão alcançável sob diferentes cenários orçamentários e de capacidade, e a robustez das soluções por meio de análise de sensibilidade sobre os parâmetros de efetividade.

1.3 Organização do Texto

O restante deste texto está organizado em cinco capítulos. O Capítulo 2 apresenta os conceitos preliminares necessários à compreensão do trabalho, abrangendo as definições e a notação relativas à evasão escolar, aos fundamentos de aprendizado de máquina utilizados na estimação do risco inicial de evasão, à otimização combinatória e à Programação Linear Inteira e à teoria de complexidade computacional.

O Capítulo 3 revisa a literatura relacionada, organizada em três frentes: os modelos preditivos de risco de evasão e as técnicas de explicabilidade associadas; as abordagens prescritivas voltadas à avaliação e à alocação de intervenções, fundamentadas na inferência causal e apoiadas sobretudo em estudos experimentais e quase-experimentais; e as aplicações de Pesquisa Operacional a problemas de planejamento e alocação de recursos no contexto educacional.

O Capítulo 4 descreve os materiais e métodos. Apresenta os microdados do Censo Escolar do INEP e as características estruturais de escolas e turmas consideradas na definição das intervenções, detalha os modelos preditivos empregados na estimação do risco inicial, descreve a calibração dos parâmetros de efetividade a partir da literatura e especifica os métodos exatos e heurísticos adotados na resolução do problema de otimização, bem como o protocolo experimental e as métricas de avaliação.

O Capítulo 5 reúne os resultados e sua discussão. Inicia com as contribuições de natureza teórica, apresentando a definição formal do PEE, a demonstração de sua NP-dificuldade por redução a partir do Problema da Cobertura Exata por 3-Conjuntos e a formulação de Programação Linear Inteira proposta. Em seguida, expõe os resultados experimentais, incluindo a avaliação de desempenho dos métodos propostos, a magnitude da redução de evasão alcançável sob diferentes cenários orçamentários, de capacidade e equidade, e a análise de sensibilidade em relação à efetividade estimada. Os resultados são confrontados com as hipóteses de pesquisa enunciadas na Seção 1.1.

Por fim, o Capítulo 6 apresenta as conclusões do trabalho, retomando as contribuições, discutindo suas limitações e apontando direções para trabalhos futuros.

Capítulo 2

Conceitos Preliminares

2.1 Evasão Escolar e Intervenções Preventivas

Esta seção define o vocabulário do problema de alocação de intervenções tratado neste trabalho. Adota-se a definição do Ministério da Educação, segundo a qual a evasão é a condição do aluno que, tendo sido regularmente matriculado em um ano letivo, não efetua matrícula no ano seguinte [3]. Essa é uma condição que se manifesta no nível do indivíduo, mas que decorre de um desengajamento prolongado e não de uma decisão súbita [8, 23], cujas causas se distribuem por fatores individuais, familiares, escolares e comunitários [18]. Como resultado, estudantes diferentes chegam a um mesmo ano letivo com propensões distintas de evadir.

Chama-se *risco inicial de evasão* a propensão de um aluno regularmente matriculado de evadir na ausência de qualquer intervenção. Por depender de múltiplos fatores, esse risco é heterogêneo entre alunos e pode ser estimado a partir de seus dados, tarefa em que se concentram os sistemas de alerta precoce e os modelos de aprendizado de máquina [6, 20]. Neste trabalho, o risco inicial é tomado como dado de entrada do problema de alocação e a forma de estimá-lo é tratada no Capítulo 4.

Denomina-se *intervenção preventiva* ou somente *intervenção* qualquer ação aplicada com o intuito de reduzir o risco de evasão, como bolsa auxílio, transporte escolar, reforço pedagógico ou apoio psicológico. As revisões sistemáticas e meta-análises da área mostram que existe um repertório de intervenções com efeito positivo sobre a permanência escolar, e que esse efeito difere entre os tipos existentes [26, 9]. Associa-se a cada tipo de intervenção uma *efetividade*, entendida como a redução proporcional que ela produz sobre o risco do aluno por ela alcançado.

Boa parte das intervenções de combate à evasão não atua sobre indivíduos isolados, e sim de forma estrutural sobre escolas e turmas, como ocorre com reorganização de turmas, infraestrutura e serviços de apoio [26, 9]. Para considerar isso, define-se uma *unidade de alocação* como o alvo concreto de uma intervenção, podendo ser uma escola, uma turma ou um aluno isolado. Cada tipo de intervenção atua em seu nível próprio, e um aluno é alcançado por tudo o que foi destinado às unidades que o contêm, ou seja, à sua escola, à sua turma e a ele próprio. Esse é também o nível em que a Pesquisa Operacional tradicionalmente trata a alocação de recursos educacionais [12, 21, 17].

Quando um mesmo aluno é alcançado por mais de uma intervenção, seus efeitos são

combinados sob a hipótese de efeitos independentes, de forma multiplicativa sobre o risco remanescente: cada intervenção atua sobre o risco que sobrou após as demais. Essa regra de composição é preferível à simples soma de reduções por permanecer sempre dentro de limites válidos e por refletir retornos decrescentes, já que intervenções sucessivas atuam sobre uma parcela de risco cada vez menor. A calibração das efetividades que alimentam essa regra é detalhada no Capítulo 4.

Por fim, a aplicação de intervenções consome recursos. Os *custos* de uma intervenção podem ser separado em uma parcela fixa, que ocorre uma única vez quando a intervenção é implantada em uma unidade, cobrindo itens como treinamento, desenvolvimento de material e aquisição inicial, e uma parcela variável, que é contabilizada por aluno alcançado, cobrindo itens que escalam com o número de atendidos, como material, horas de monitoria ou valor de bolsa [1, 4]. Há um *orçamento* total disponível, restrição central de países em desenvolvimento e principal motivação para buscar alocações de alto custo-benefício [25, 26], e cada tipo de intervenção possui uma *capacidade*, isto é, um número máximo de alunos que pode atender, refletindo a oferta limitada de recursos como vagas de bolsa, assentos de transporte ou profissionais disponíveis [25, 17].

Esses elementos, risco inicial, intervenções e suas efetividades, unidades e níveis de alocação, custos, orçamento e capacidade, são os fundamentos a partir dos quais o Capítulo 4 constrói as instâncias do problema e o Capítulo 5 formaliza como um problema de otimização combinatória.

Além desses elementos descritivos, a alocação de intervenções envolve uma decisão distributiva, e não apenas de eficiência. Na Pesquisa Operacional, distinguem-se duas noções complementares de equidade: a horizontal, que trata igualmente unidades em igual condição, e a vertical, que destina mais recursos a quem tem maior necessidade [14, 21]. No contexto da evasão, a leitura pertinente é a vertical, pois um critério puramente agregado tende a concentrar os recursos nas unidades em que eles rendem mais e a desatender populações mais vulneráveis, problema já reconhecido na alocação de recursos escolares [17]. Neste trabalho, a equidade é definida sobre dimensões observáveis no nível de escola, como região e contexto socioeconômico do território, e é incorporada como parte central do problema de alocação.

2.2 Aprendizado de Máquina

O risco inicial de evasão, tomado como entrada do problema de alocação, é estimado a partir dos dados de cada aluno por meio de aprendizado de máquina supervisionado. No aprendizado supervisionado, dispõe-se de um conjunto de exemplos rotulados, e o objetivo é induzir uma função que associe as características de cada unidade a seu rótulo, de modo a generalizar essa associação para unidades novas, ainda não rotuladas. Formalmente, cada aluno a é descrito por um vetor de atributos $x_a \in \mathbb{R}^d$, obtido de seus registros acadêmicos e socioeconômicos, e por um rótulo $y_a \in \{0, 1\}$, que indica se o aluno evadiu. A estimação do risco de evasão configura, assim, um problema de classificação binária, em que se busca uma função h que aproxime a relação entre atributos e desfecho.

Para os fins deste trabalho, a saída relevante do classificador não é o rótulo predito,

mas o valor contínuo $h(x_a) \in [0, 1]$, interpretável como a probabilidade estimada de o aluno evadir. É esse valor que fornece o risco inicial r_a empregado na formalização do Capítulo 5, que alimenta a entrada da etapa de otimização. A qualidade dessa estimativa depende, portanto, de o valor estimado refletir de maneira fidedigna a propensão à evasão, e não apenas de o classificador separar corretamente as duas classes.

A indução de h apoia-se na separação dos dados em subconjuntos de treino e de teste. O modelo é ajustado sobre o conjunto de treino e avaliado sobre o de teste, que permanece intocado durante o treinamento, com o intuito de estimar sua capacidade de generalização sobre amostras não vistas. Essa distinção é necessária porque um modelo pode ajustar-se a particularidades do conjunto de treino sem capturar o padrão subjacente, fenômeno conhecido como sobreajuste (*overfitting*), que se manifesta em bom desempenho no treino e desempenho degradado no teste.

A avaliação do classificador exige um cuidado adicional no contexto da evasão, devido ao desbalanceamento entre as classes. Os alunos evadidos constituem uma fração pequena do total, abaixo de 5% nos dados históricos do Censo Escolar. Nesse cenário, a acurácia global é uma métrica enganosa, pois um classificador que não preveja evasão pode alcançar acurácia maior que 95% e ainda assim ser irrelevante para o problema. Devido a isso, adotam-se métricas sensíveis ao desempenho sobre a classe minoritária, como precisão, *recall* e a área sob a curva característica de precisão e *recall*, entre outras adequadas a dados desbalanceados. As técnicas específicas de tratamento do desbalanceamento e o protocolo de avaliação adotados são detalhados no Capítulo 4.

Os modelos utilizáveis nessa tarefa podem ser divididos entre dois grupos que estão presentes na literatura e serão explorados no Capítulo 3. De um lado, há modelos diretamente interpretáveis, como a regressão logística e os modelos aditivos generalizados (*GAMs*), cuja estrutura decompõe a predição na soma de contribuições de cada atributo, permitindo inspecionar isoladamente como cada um influencia a estimativa. De outro, há modelos de maior complexidade, como métodos de *ensemble* e redes neurais, que costumam alcançar desempenho preditivo superior ao custo de operarem como caixas-pretas. Para esses últimos, utilizam-se técnicas de explicabilidade que atribuem a cada atributo uma medida de sua contribuição para uma predição, como por exemplo *SHAP* e *SAGE*. A comparação entre esses dois grupos, quanto ao desempenho preditivo e à interpretabilidade, integra os objetivos deste trabalho e é explorada no Capítulo 4.

2.3 Otimização Combinatória, Complexidade e Métodos de Solução

A alocação de intervenções proposta no Capítulo 5 é um problema de otimização combinatória e esta subseção reúne os fundamentos necessários para defini-lo, caracterizar sua dificuldade e resolvê-lo. Um problema de otimização combinatória associa a cada instância um conjunto finito de soluções viáveis e uma função objetivo que atribui um valor a cada solução. O problema consiste em encontrar uma solução viável cujo valor seja ótimo, ou seja, mínimo ou máximo conforme o problema. No caso da Evasão Escolar, uma instância reúne os alunos, as intervenções e os parâmetros de risco, efetividade, custo, orçamento

e capacidade; uma solução viável é uma atribuição de intervenções às unidades que respeita orçamento e capacidade; e a função objetivo, a ser minimizada, é o risco agregado de evasão remanescente após as intervenções. A quantidade de soluções viáveis cresce, em geral, de forma exponencial no tamanho da instância, o que inviabiliza a enumeração exaustiva e motiva o uso de técnicas de modelagem e solução mais elaboradas.

Entre essas técnicas, a Programação Linear Inteira está presente em diversos problemas de Otimização Combinatória na literatura. Um programa linear é o problema de minimizar ou maximizar uma função objetivo linear sobre um conjunto de variáveis de decisão contínuas sujeitas a restrições lineares de igualdade e desigualdade. Programas lineares admitem solução em tempo polinomial e a região por eles definida é um poliedro convexo cujos vértices concentram as soluções ótimas. Quando pelo menos uma parte das variáveis assume apenas valores inteiros, obtém-se um programa linear inteiro, e o caso em que as variáveis são restritas ao conjunto $\{0, 1\}$ é chamado também de programa linear binário. Esse tipo é o de interesse deste trabalho, uma vez que modela as decisões de implantar ou não uma intervenção em uma unidade. A exigência de integralidade altera qualitativamente a dificuldade do problema, que deixa de ser resolvível em tempo polinomial no caso geral.

A resolução exata de um programa inteiro tipicamente passa por realizar sua relaxação linear, obtida ao substituir a restrição de integralidade pela exigência mais fraca de que as variáveis pertençam a um intervalo contínuo. O valor ótimo da relaxação fornece um limitante inferior ou superior para o valor ótimo do problema inteiro. Esse limitante sustenta o método de *branch-and-bound*, no qual o espaço de soluções é sucessivamente particionado e ramos são descartados quando seu limitante indica a inviabilidade de conter a solução ótima. Os *solvers* de otimização empregados na avaliação exata descrita no Capítulo 4 implementam variantes desse método, e é a partir deles que se demonstra por que a resolução exata pode tornar-se computacionalmente proibitiva à medida que a instância cresce.

Essa limitação de escalabilidade é um reflexo da dificuldade intrínseca do problema, cuja caracterização é objeto da teoria da complexidade computacional [10]. Essa teoria classifica problemas segundo os recursos exigidos para resolvê-los, e opera sobre problemas de decisão, aqueles cuja resposta é sim ou não, aos quais todo problema de otimização pode ser associado ao perguntar-se se existe solução viável com valor melhor que um dado limiar. A classe P reúne os problemas de decisão resolvíveis em tempo polinomial, e a classe NP reúne aqueles para os quais uma solução afirmativa, uma vez fornecida, pode ser verificada em tempo polinomial. Um problema é dito NP-difícil quando é ao menos tão difícil quanto qualquer problema em NP, e NP-completo quando, além disso, pertence a NP. Não se conhece algoritmo de tempo polinomial para os problemas NP-difíceis, e a hipótese amplamente aceita de que $P \neq NP$ implica que tal algoritmo não existe.

O instrumento central para estabelecer a dificuldade de um problema é a redução polinomial. Dizer que um problema Π_1 se reduz em tempo polinomial a um problema Π_2 significa exibir uma transformação, computável em tempo polinomial, que leva toda instância de Π_1 a uma instância de Π_2 , de modo que a resposta se preserve. Quando isso ocorre e Π_1 é sabidamente NP-difícil, conclui-se que Π_2 é ao menos tão difícil quanto Π_1 , e portanto também NP-difícil, pois um algoritmo eficiente para Π_2 resolveria Π_1 por

meio da transformação. É por essa via que o Capítulo 5 estabelece a NP-dificuldade do problema de alocação, reduzindo a ele um problema combinatório clássico cuja dificuldade já é conhecida.

Estabelecida a intratabilidade da resolução exata em escala, justifica-se o recurso a métodos aproximados. Uma heurística é um procedimento que busca soluções de boa qualidade em tempo reduzido, sem garantia de otimalidade, e uma meta-heurística é uma estratégia geral de busca, aplicável a diferentes problemas, que orienta a exploração do espaço de soluções na tentativa de escapar de ótimos locais. A qualidade de uma solução assim obtida é aferida pelo *gap* de otimalidade, a diferença relativa entre o valor da solução encontrada e um limitante para o valor ótimo, que quantifica quão longe, no pior caso, a solução se encontra do ótimo. Os métodos heurísticos e meta-heurísticos concretamente adotados neste trabalho, bem como o protocolo de comparação com a solução exata, são definidos no Capítulo 4.

Capítulo 3

Revisão da Literatura

A literatura relacionada a este trabalho organiza-se em torno de um deslocamento progressivo da forma de análise, que parte da caracterização descritiva do fenômeno da evasão, avança para a predição de quais alunos estão em risco de evadir e vai em direção à prescrição do que fazer a respeito. A primeira parte é o da análise descritiva, que busca mensurar a magnitude do fenômeno e estimar os fatores a ele associados. A definição operacional de evasão e a organização de suas causas nos níveis individual, familiar, escolar e comunitário foram apresentadas no Capítulo 2, e a magnitude do problema no contexto brasileiro foi exposta no Capítulo 1.

A análise descritiva, contudo, opera no plano agregado. Ela informa quais fatores elevam, em média, a propensão à evasão, mas não produz uma estimativa individualizada do risco de cada aluno matriculado. É desse limite que surge a demanda preditiva, tratada a seguir.

3.1 Predição do Risco de Evasão e Explicabilidade

A resposta predominante da literatura ao desafio da evasão tem sido a construção de Sistemas de Alerta Precoce apoiados em modelos de aprendizado de máquina, que estimam, a partir dos registros de cada aluno, sua propensão a evadir antes que o abandono se concretize. A escala e a maturidade dessa frente são atestadas por revisões sistemáticas recentes, que catalogam centenas de estudos e convergem quanto ao predomínio de técnicas supervisionadas sobre dados educacionais. Shi et al. [?] revisam uma década de aplicações de aprendizado de máquina à identificação de alunos em risco; Albreiki et al. [?] sistematizam a predição de desempenho estudantil por essas técnicas; e Córdova et al. [?] mapeiam o campo no ensino superior, evidenciando a consolidação metodológica do problema. Esse volume acumulado licencia, no restante desta seção, tratar seletivamente os trabalhos individuais, privilegiando os que introduzem eixos metodológicos relevantes para as etapas posteriores.

No plano aplicado, o veículo dessa analítica preditiva é o Sistema de Alerta Precoce. Sorensen [?] situa esses sistemas no contexto da administração educacional e do uso de grandes bases de dados para antecipar o risco de evasão, fixando a moldura em que os gestores operam. Instâncias concretas dessa moldura aparecem em De Vasconcelos et

al. [?], que propõem um modelo relacional para a identificação de alunos em risco, e em Skittou et al. [?], que descrevem um sistema de alerta orientado ao apoio à decisão no âmbito escolar.

Os modelos que alimentam esses sistemas evoluíram dos classificadores clássicos às arquiteturas de aprendizado profundo. No registro clássico concentra-se a maior parte das aplicações, que empregam algoritmos como regressão logística, florestas aleatórias e máquinas de vetores de suporte sobre registros administrativos e acadêmicos, com desempenho robusto e amplamente replicado em diferentes sistemas educacionais [?, ?, ?]. Passos em direção a maior sofisticação surgem com os métodos de conjunto, que combinam múltiplos classificadores para mitigar a instabilidade de modelos isolados [?], e culminam nas redes neurais profundas: Aouifi e Hajji [?] empregam uma arquitetura híbrida LSTM-DNN para capturar a dimensão temporal do desengajamento e antecipar precocemente os alunos em risco. Para os fins desta dissertação, contudo, essa progressão importa menos por suas diferenças técnicas do que por um resultado comum: a viabilidade de estimar, com qualidade, o risco individual de evasão a partir de dados observáveis.

Independentemente da técnica, três eixos metodológicos recorrem nessa literatura e sustentam a decisão, adotada no Capítulo 5, de tomar o risco inicial como dado de entrada do problema de alocação. O primeiro é a antecedência da predição, isto é, quanto cedo o risco pode ser sinalizado. Psyridou et al. [?] demonstram que a evasão no ensino médio pode ser prevista já ao fim do ensino primário, ampliando a janela disponível para a ação preventiva, enquanto Ameri et al. [?] tratam o problema por análise de sobrevivência, estimando não apenas se, mas quando o aluno tende a evadir. O segundo eixo é a qualidade dos dados, em particular o desbalanceamento entre alunos evadidos e não evadidos, que compromete o aprendizado e exige técnicas específicas de reamostragem, como discute Mduma [?]. O terceiro eixo diz respeito às fontes de dados e à transferibilidade entre contextos. Uma vertente explora trilhas de aprendizagem e registros de ambientes virtuais [?, ?, ?], ao passo que outra evidencia a aplicabilidade das mesmas técnicas em geografias distintas. Nesse ponto, Pereira et al. [?] ancoram o precedente brasileiro, que se soma às aplicações já mencionadas em contextos como Egito e Itália. A predição do risco de evasão em dados brasileiros constitui, portanto, terreno já consolidado, o que delimita desde logo o espaço em que reside a contribuição inédita deste trabalho, e que não está na predição.

À medida que os modelos preditivos ganharam complexidade, tornou-se central a preocupação com sua interpretabilidade, uma vez que arquiteturas de alto desempenho operam como caixas-pretas de difícil escrutínio por professores e gestores. Em resposta, técnicas de Inteligência Artificial Explicável, como SHAP e SAGE, passaram a acompanhar os preditores, revelando os atributos que mais pesam na estimativa de risco. Radić et al. [?] combinam classificadores otimizados por meta-heurísticas com técnicas de explicabilidade para compreender os fatores associados à evasão, ilustrando o esforço de tornar a predição inteligível. É também no plano preditivo que a literatura de evasão incorpora a preocupação distributiva: Gao e Ni [?] propõem uma rede adversária para tornar a predição de evasão mais justa entre grupos, o que evidencia que a equidade, quando tratada nessa frente, é entendida como propriedade do modelo preditivo e não como restrição da decisão de alocação, distinção retomada na Seção 3.3. O passo mais avançado nessa

direção é dado por Nagy e Molontay [?], cuja explicabilidade se orienta explicitamente à intervenção personalizada, sugerindo, a partir dos atributos de risco, alvos plausíveis de ação.

O gesto de Nagy e Molontay marca o limite desta frente. A explicabilidade estica a predição em direção à ação, ao apontar quais atributos elevam o risco e ao sugerir onde intervir, mas permanece aquém da decisão que o gestor enfrenta. Ela explica a predição, porém não estima o efeito de agir, não compara ações alternativas nem aloca recursos escassos sob restrição. Identificar os fatores de risco de um aluno não determina qual intervenção reduziria efetivamente esse risco, tampouco como distribuir um conjunto de intervenções sobre uma população heterogênea dentro de um orçamento. É precisamente esse deslocamento, do risco estimado para o efeito esperado de uma intervenção, que a literatura recolhe ao voltar-se à análise prescritiva, objeto da Seção 3.2.

3.2 Da Predição à Prescrição: Inferência Causal e Efetividade das Intervenções

Identificar quais alunos estão em risco não determina o que fazer a respeito, e é dessa insuficiência que emerge um movimento crescente e estruturado na literatura rumo à análise prescritiva, que desloca o foco de quem irá evadir para o que fazer diante desse risco. Esse movimento apoia-se em métodos de inferência causal, cujo objeto de estimação deixa de ser o risco inicial e passa a ser a redução esperada nesse risco decorrente da aplicação de uma intervenção. A distinção é substantiva: enquanto a etapa preditiva responde ao que tende a acontecer, a etapa prescritiva pergunta o que fazer para alterar esse curso, e requer, para tanto, uma estimativa do efeito de agir, e não apenas da propensão a evadir.

Tais estimativas de efeito derivam, em grande parte, de estudos experimentais e quase-experimentais, que constituem a principal fonte de evidência sobre a efetividade de intervenções educacionais. Revisões sistemáticas e meta-análises sintetizam esse corpo de evidência e sustentam duas conclusões centrais para este trabalho. Wilson et al. [?], em meta-análise conduzida no âmbito da Campbell Collaboration, e Freeman e Simonsen [?], em revisão sistemática de políticas e práticas de combate à evasão, estabelecem que existe um repertório de intervenções com efeito positivo sobre a permanência escolar e que esse efeito difere entre os tipos de intervenção. É essa literatura de síntese que autoriza, nesta dissertação, tratar a efetividade como parâmetro calibrável de entrada, submetido a análise de sensibilidade conforme detalhado no Capítulo ??, em vez de objeto a ser estimado causalmente dentro do problema de otimização. A estimação causal individualizada dos efeitos, embora represente o caminho metodologicamente mais exigente, é assim posicionada como possibilidade futura, e não como pré-requisito da formulação aqui proposta.

Na fronteira desse movimento situa-se justamente a estimação individualizada do efeito de uma intervenção. Olaya et al. [?] trazem a modelagem de *uplift* para a prevenção da evasão, estimando o efeito individual do tratamento, isto é, a redução de risco atribuível à intervenção em cada aluno, e deslocando o critério de seleção do risco inicial para a sensibilidade esperada à ação. Os autores observam que, até onde apuraram, nenhum estudo anterior havia customizado a atribuição de ações de retenção com base na respon-

sividade esperada de cada aluno à intervenção, e não apenas em sua propensão a evadir. Na mesma direção, Maldonado [?] redefine as métricas de retorno associadas à retenção estudantil, de modo a alinhar a decisão de a quem direcionar a ação a um critério explícito de custo e benefício. Este trabalho incorpora o deslocamento conceitual que esses estudos consolidam, ao orientar a alocação pela redução esperada de evasão e não apenas pelo risco inicial, uma vez que risco e responsividade não são necessariamente correlacionados, sem, contudo, depender de sua estimação causal a partir dos dados.

A aplicação de intervenções, por fim, consome recursos, e a literatura prescritiva tem incorporado de forma crescente a dimensão de custo. Diretrizes de custeio propostas pelo J-PAL [?] e por Carter et al. [?] fornecem protocolos para a análise de custo-efetividade de intervenções educacionais, distinguindo componentes fixos e variáveis que este trabalho retoma na construção das instâncias. Em escala, Vazquez et al. [?] avaliam, por meio de ensaio controlado randomizado em milhares de escolas, a implantação de sistemas de alerta de baixo custo, evidenciando que a restrição orçamentária é elemento central em países em desenvolvimento e principal motivação para buscar alocações de alto custo-benefício. É essa dimensão de orçamento e capacidade que converte a prescrição de uma questão de estimação de efeito em uma questão de decisão sob restrição.

Apesar desses avanços, as abordagens prescritivas permanecem aquém do problema enfrentado na prática pelos gestores educacionais. Como a própria literatura reconhece, e ainda que se admita a necessidade de tratar múltiplos fatores de risco em conjunto, a maior parte da produção avalia uma única intervenção por vez, aplicada a indivíduos ou pequenos grupos. O esforço concentra-se em medir o impacto de um programa isolado, e mesmo a modelagem de *uplift*, ao customizar a atribuição, o faz para um tratamento por vez, sem selecionar conjuntamente um portfólio de intervenções nem distribuí-lo sobre uma população estudantil heterogênea sob restrições de orçamento e capacidade. Essa última decisão, a de escolher e alocar múltiplos tipos de intervenção sob recursos escassos, é por natureza um problema de otimização combinatória, objeto clássico da Pesquisa Operacional, cuja aplicação a problemas educacionais é revisada na Seção 3.3.

3.3 Pesquisa Operacional na Alocação de Recursos Educacionais

A decisão delineada ao fim da Seção 3.2, escolher e distribuir múltiplos tipos de intervenção sobre uma população heterogênea sob orçamento e capacidade, é, por sua natureza, um problema de alocação de recursos escassos sob restrição, objeto clássico da Pesquisa Operacional. O repertório de métodos dessa disciplina, da programação matemática às meta-heurísticas, é sistematizado por Petropoulos et al. [?] em ampla revisão de suas técnicas e aplicações. No contexto educacional especificamente, a Pesquisa Operacional possui tradição consolidada, revisada por Johnes [?], que documenta seu emprego em problemas como programação de horários, avaliação de eficiência e alocação de professores, turmas e infraestrutura. Badiie et al. [?], ao organizarem as aplicações de Pesquisa Operacional em educação segundo a distinção entre analítica descritiva, preditiva e prescritiva, evidenciam que a vertente prescritiva, aquela que recomenda cursos de ação ótimos sob restrição, é a

menos desenvolvida das três, o que já sinaliza o espaço em que este trabalho se insere.

O análogo estrutural mais próximo à formulação aqui proposta é o de Mayerle et al. [?], que modelam a alocação de recursos do sistema público de ensino brasileiro como um problema de programação linear inteira mista, otimizando simultaneamente o pareamento entre alunos, escolas, turmas, professores e salas em nível municipal ou metropolitano. O trabalho compartilha com esta dissertação tanto o ferramental, a programação inteira aplicada a redes escolares brasileiras, quanto a escala de decisão, o nível de escolas e turmas. Distingue-se dela, contudo, no objeto: Mayerle et al. alocam recursos de oferta para atender à demanda de matrícula, ao passo que este trabalho aloca intervenções preventivas com o objetivo de reduzir o risco agregado de evasão, um problema com função objetivo e restrições de natureza distinta.

Outras aplicações confirmam a maturidade da alocação de recursos educacionais como problema de otimização. Tsamis et al. [?] formulam a seleção e alocação de professores como problema de otimização sob restrições, avaliando abordagens exatas e heurísticas, enquanto Jiang [?] aborda a distribuição de recursos educacionais em nível governamental, contrastando a programação linear com técnicas de aprendizado profundo. Em conjunto, esses trabalhos demonstram que a alocação de recursos educacionais sob restrição é território rotineiramente tratado pela Pesquisa Operacional, com instrumentos maduros para lidar com orçamento, capacidade e múltiplos níveis organizacionais.

É também nessa frente que a preocupação distributiva assume feição distinta da observada na Seção 3.1. Enquanto a literatura preditiva trata a equidade como propriedade do modelo, a ser assegurada por meio de justiça entre grupos na estimativa de risco, a Pesquisa Operacional dispõe de uma tradição que trata a equidade como componente da própria decisão de alocação. Karsu e Morton [?] sistematizam a otimização avessa à iniquidade, mostrando como incorporar critérios distributivos diretamente à função objetivo ou às restrições de um modelo, de modo a evitar que a busca por eficiência agregada concentre recursos nas unidades de maior responsividade e desatenda populações vulneráveis, problema já reconhecido por Mayerle et al. [?] na alocação de recursos escolares. Essa leitura da equidade, como restrição da decisão e não como propriedade da predição, é a que este trabalho adota, e é o que fundamenta a incorporação de um piso de redução por grupo como elemento central da formulação, e não como refinamento posterior, conforme desenvolvido no Capítulo 5.

Resta um conjunto de trabalhos que aproxima otimização e evasão sem, todavia, alcançar a decisão de alocação de intervenções. Jiménez et al. [?] empregam otimização multiobjetivo temporal para a predição do risco de evasão, e Pan et al. [?] recorrem ao aprendizado por reforço multiobjetivo para equilibrar objetivos concorrentes na predição. Em ambos, porém, o aparato de otimização é posto a serviço do preditor, para calibrar seus objetivos ou seu desempenho, e não da decisão sobre quais intervenções aplicar, a quem e sob quais restrições. A otimização orbita a evasão sem tocar a alocação. Esse é o ponto em que as duas trajetórias percorridas por este capítulo, a da prescrição em evasão e a da alocação de recursos em Pesquisa Operacional, permanecem separadas: a primeira chegou à estimação do efeito de intervenções, mas uma por vez; a segunda domina a alocação sob restrição, mas nunca foi dirigida à evasão. A confluência das duas, a alocação conjunta de múltiplas intervenções preventivas sob orçamento, capacidade e equidade, é

a lacuna que a Seção 3.4 caracteriza de forma explícita.

3.4 Síntese e Posicionamento da Pesquisa

As três frentes percorridas neste capítulo respondem, cada uma, a uma pergunta distinta do gestor educacional, e é a superposição incompleta de suas respostas que delimita a contribuição desta dissertação. A analítica preditiva, revisada na Seção 3.1, responde a quem tende a evadir, estimando com qualidade o risco individual a partir de dados observáveis, mas detém-se no diagnóstico, sem prescrever ação. A analítica prescritiva, revisada na Seção 3.2, avança para o que fazer, estimando o efeito esperado de intervenções por meio da inferência causal, mas o faz avaliando uma intervenção por vez, sobre indivíduos ou pequenos grupos, sem selecionar conjuntamente um portfólio de ações. A Pesquisa Operacional, revisada na Seção 3.3, domina a alocação de recursos escassos sob restrição de orçamento e capacidade, e já foi aplicada a problemas educacionais estruturalmente vizinhos, mas nunca foi dirigida à decisão de alocar intervenções preventivas contra a evasão.

A dimensão distributiva, por sua vez, atravessa o capítulo tratada de forma parcial. Na frente preditiva, a equidade é entendida como propriedade do modelo, a ser assegurada por justiça entre grupos na estimativa de risco; na frente de Pesquisa Operacional, existe o instrumental para tratá-la como restrição da própria decisão de alocação, mas ele nunca foi mobilizado no contexto da evasão. Nenhuma das frentes reúne, portanto, a alocação conjunta de múltiplas intervenções à incorporação da equidade como restrição estrutural da decisão.

O quadro que emerge é o de trajetórias que se aproximam sem se encontrar. A prescrição em evasão chegou à estimação do efeito de intervenções, mas parou na ação isolada; a alocação sob restrição em Pesquisa Operacional dispõe do ferramental completo, mas não foi voltada à evasão; e trabalhos que combinam otimização e evasão o fazem a serviço do preditor, e não da decisão de intervir. Cada contribuição existente cobre, quando muito, um subconjunto das dimensões que o problema real exige, a saber, a predição do risco, a estimação do efeito das intervenções, a seleção conjunta de múltiplos tipos de intervenção, a restrição de orçamento e capacidade e a equidade na distribuição, e a interseção plena dessas dimensões permanece vazia.

É essa interseção que este trabalho ocupa. A formalização da evasão escolar como um problema de otimização combinatória de alocação de intervenções preventivas, sob restrições de orçamento, capacidade e equidade, situa-se precisamente no ponto em que as três frentes convergem e que nenhuma delas, isoladamente, alcança. A predição fornece o risco inicial como entrada, a literatura de inferência causal fornece a efetividade das intervenções como parâmetro calibrável, e a Pesquisa Operacional fornece o arcabouço de modelagem e solução; o que este trabalho aporta é a integração dessas peças em uma única formulação, cuja definição, análise de complexidade e resolução constituem o objeto do Capítulo 5.

Capítulo 4

Materiais e Métodos

4.1 Base de Dados

4.2 Estimativa do Risco Inicial

4.3 Construção das instâncias

4.3.1 Cálculo da efetividade

4.4 Métodos Exatos

4.5 Métodos Heurísticos

Capítulo 5

Resultados e Discussão

5.1 Formalização do PEE

Formaliza-se agora, como um problema de otimização combinatória, a noção de evasão e os elementos introduzidos na Seção 2.1. A Definição 5.1 fixa a entrada, a solução e a função objetivo do problema.

Definição 5.1 (Problema da Evasão Escolar). Uma instância do *Problema da Evasão Escolar* (PEE) é uma tupla $\langle A, U, I, r, e, cf, cv, B, q \rangle$ definida como segue.

Entrada. O conjunto $A = \{1, \dots, n\}$ reúne os estudantes matriculados, e $r: A \rightarrow [0, 1]$ associa a cada aluno a seu risco inicial de evasão r_a . A estrutura de alocação é dada por uma família de unidades U , em que cada $u \in U$ é um subconjunto de alunos $u \subseteq A$ com um nível associado, e as unidades de um mesmo nível particionam A . O conjunto $I = \{1, \dots, m\}$ reúne os tipos de intervenção; cada tipo i possui um nível, e $I_u \subseteq I$ denota as intervenções admissíveis na unidade u , isto é, as do nível de u . A função $e: I \rightarrow [0, 1]$ associa a cada tipo i sua efetividade e_i , a redução proporcional que i produz sobre o risco do aluno por ela alcançado. Os recursos são descritos pelo custo fixo $cf_{i,u} \in \mathbb{R}_+$, incorrido quando o tipo i é implantado na unidade u ; pelo custo variável $cv_i \in \mathbb{R}_+$, incorrido por aluno alcançado por i ; pelo orçamento total $B \in \mathbb{R}_+$; e pela capacidade $q_i \in \mathbb{N}$, o número máximo de alunos atendíveis pelo tipo i .

Solução. Uma solução atribui a cada unidade $u \in U$ um subconjunto de intervenções admissíveis $X_u \subseteq I_u$. Dessa atribuição deriva-se, para cada aluno $a \in A$, o conjunto de intervenções que efetivamente o alcança, dado pela união das intervenções de todas as unidades que o contêm:

$$T(a) = \bigcup_{u \in U: a \in u} X_u. \quad (5.1)$$

A solução é *viável* quando o custo total não excede o orçamento,

$$\sum_{u \in U} \sum_{i \in X_u} cf_{i,u} + \sum_{i \in I} cv_i \cdot |\{a \in A : i \in T(a)\}| \leq B, \quad (5.2)$$

e nenhuma intervenção atende mais alunos do que sua capacidade,

$$|\{a \in A : i \in T(a)\}| \leq q_i \quad \text{para todo } i \in I. \quad (5.3)$$

Objetivo. Os efeitos das intervenções que alcançam um mesmo aluno combinam-se de forma multiplicativa sobre o risco remanescente, de modo que o risco residual do aluno a é $r_a \prod_{i \in T(a)} (1 - e_i)$. O objetivo é minimizar o risco agregado de evasão após as intervenções, isto é, o número esperado de evadidos remanescente:

$$\min_{\{X_u\}_{u \in U}} \sum_{a \in A} r_a \prod_{i \in T(a)} (1 - e_i). \quad (5.4)$$

Observação 5.1 (Parâmetros como entrada). O risco inicial r e a efetividade e são dados de entrada do PEE, e não objetos a estimar dentro do problema de otimização. A estimação de r e a calibração de e são tratadas no Capítulo 4.

A Definição 5.1 descreve o problema em sua forma puramente eficiente. Como um critério agregado pode concentrar as intervenções nas unidades de maior responsividade e desatender grupos vulneráveis, este trabalho adota como objeto central o PEE com equidade, que acrescenta à forma base um piso de redução por grupo.

Definição 5.2 (PEE com equidade). Seja G uma partição dos alunos em grupos induzida por uma dimensão observável no nível de escola, e seja $A_g \subseteq A$ o conjunto de alunos do grupo $g \in G$. Para uma solução $\{X_u\}_{u \in U}$, a *redução de risco* entregue ao grupo g é

$$\Delta_g = \sum_{a \in A_g} r_a \left(1 - \prod_{i \in T(a)} (1 - e_i) \right). \quad (5.5)$$

Sejam $R_g = \sum_{a \in A_g} r_a$ a massa de risco do grupo g e $R = \sum_{a \in A} r_a$ a massa total. Denote por Δ_g^* a maior redução que o grupo g alcançaria se otimizado isoladamente sob orçamento proporcional $B_g = B R_g / R$, isto é, o valor ótimo da instância do PEE da Definição 5.1 restrita aos alunos de A_g e às unidades que os contêm, com orçamento B_g e capacidades q_i . Dado um parâmetro $\delta \in [0, 1]$, uma instância do *PEE com equidade* acrescenta às condições de viabilidade da Definição 5.1 o *piso de equidade*

$$\Delta_g \geq \delta \Delta_g^* \quad \forall g \in G, \quad (5.6)$$

preservando a mesma função objetivo.

Observação 5.2 (Parâmetro de equidade). O parâmetro δ regula o compromisso entre eficiência agregada e equidade. Em $\delta = 0$ os pisos são inativos e recupera-se exatamente a forma base da Definição 5.1; à medida que δ cresce, cada grupo é forçado a aproximar-se da redução que obteria sob sua fatia proporcional do orçamento, até que, para δ suficientemente alto, a competição por orçamento e capacidade pode tornar a instância inviável. A fronteira entre redução total de evasão e equidade é obtida variando-se δ , e a perda de eficiência associada a cada nível de equidade é o custo que a Hipótese H5 se propõe a quantificar.

Estabelecidas as definições, caracteriza-se a seguir a complexidade computacional do PEE.

5.2 Análise de Complexidade

Reduziremos o Problema da Cobertura Exata por 3-Conjuntos (*Exact Cover by 3-Sets*), conhecido por ser NP-difícil [13, 10], ao PEE.

Problema da Cobertura Exata por 3-Conjuntos (X3C). A entrada é uma tupla $\langle W, \mathcal{C} \rangle$, em que $W = \{w_1, w_2, \dots, w_{3m}\}$ é um conjunto de $3m$ elementos e $\mathcal{C} = \{C_1, C_2, \dots, C_t\}$ é uma coleção de subconjuntos de W com $|C_\ell| = 3$ para todo ℓ . O objetivo é decidir se existe $\mathcal{C}' \subseteq \mathcal{C}$ tal que todo elemento de W aparece em exatamente um conjunto de $\mathcal{C}'$.

Teorema 5.1. *O Problema da Evasão Escolar (PEE) é NP-difícil.*

Demonstração. Dada uma instância $\varphi = \langle W, \mathcal{C} \rangle$ de X3C, construímos uma instância $\psi = \langle A, U, I, r, e, cf, cv, B, q \rangle$ do PEE da seguinte forma:

- *Alunos (A):* para cada elemento $w_j \in W$, criamos um aluno a_j . Portanto $|A| = 3m$.
- *Intervenções (I):* para cada conjunto $C_\ell \in \mathcal{C}$, criamos uma intervenção i_ℓ . Logo $|I| = |\mathcal{C}|$.
- *Unidades (U) e admissibilidade (I_u):* para cada conjunto C_ℓ , criamos uma unidade u_ℓ com os três alunos correspondentes aos elementos de C_ℓ , e deixamos i_ℓ como sua única intervenção admissível, ou seja, $I_{u_\ell} = \{i_\ell\}$. Como dois conjuntos de $\mathcal{C}$ podem compartilhar elementos, essas unidades podem se sobrepor, por isso cada uma fica em um nível separado. Para que cada nível cubra todos os alunos, os alunos restantes são colocados em unidades individuais sem intervenção admissível.
- *Risco inicial (r):* para cada aluno a_j , definimos $r_{a_j} = 1$.
- *Custo variável (cv):* para cada intervenção i_ℓ , definimos $cv_{i_\ell} = 0$.
- *Custo fixo (cf):* para cada intervenção i_ℓ , definimos $cf_{i_\ell, u_\ell} = 1$.
- *Efetividade (e):* para cada intervenção i_ℓ , definimos $e_{i_\ell} = 1$. Ou seja, qualquer intervenção recebida anula o risco do aluno por ela alcançado.
- *Capacidade (q):* para cada intervenção i_ℓ , definimos $q_{i_\ell} = 3$.
- *Orçamento (B):* $B = m$.

Mostraremos que existe cobertura exata para X3C se e somente se existe solução para o PEE com risco total zero.

Seja $\mathcal{C}' = \{C_1, \dots, C_m\}$ uma cobertura exata de W . Construímos a solução atribuindo $X_{u_\ell} = \{i_\ell\}$ a cada unidade u_ℓ com $C_\ell \in \mathcal{C}'$, e $X_u = \emptyset$ às demais. Como $|\mathcal{C}'| = m$ e a ativação de cada intervenção em sua unidade tem custo 1, o custo total é $1 \times m = m = B$, respeitando o orçamento. Cada intervenção i_ℓ alcança os 3 alunos de u_ℓ , logo $|\{a : i_\ell \in T(a)\}| = 3 \leq q_{i_\ell}$, respeitando a capacidade. Por fim, como $\mathcal{C}'$ é cobertura exata, todo aluno a_j é alcançado por exatamente uma intervenção, de modo que o fator $(1 - e_{i_\ell}) = 0$ anula seu risco residual, e o risco total é zero.

Para a outra direção, suponha que existe uma solução para o PEE com risco total zero. Então todo aluno é alcançado por ao menos uma intervenção, pois o risco residual $r_a \prod_{i \in T(a)} (1 - e_i)$ só se anula quando algum fator é nulo, isto é, quando $T(a) \neq \emptyset$. Seja $I' = \{i_\ell \in I : X_{u_\ell} = \{i_\ell\}\}$ o conjunto de intervenções utilizadas. Como cada intervenção i_ℓ só é admissível em u_ℓ , o custo total da solução é $\sum_{i_\ell \in I'} cf_{i_\ell, u_\ell} = |I'| \times 1$. Como o custo não pode exceder $B = m$, temos $|I'| \leq m$. Por outro lado, cada intervenção atende no máximo $q_{i_\ell} = 3$ alunos, de modo que o total de alunos alcançados é no máximo $|I'| \times 3$. Como todos os $3m$ alunos são alcançados, segue que $|I'| \times 3 \geq 3m$, e portanto $|I'| \geq m$. Combinando as duas desigualdades, concluímos que $|I'| = m$. Disso resulta que os $3m$ alunos são cobertos por exatamente $3m$ incidências, ou seja, cada aluno é alcançado por exatamente uma intervenção e as unidades correspondentes são disjuntas. Definimos $C' = \{C_\ell : i_\ell \in I'\}$, que é uma cobertura exata de W .

A redução é computada em tempo polinomial: criar A requer $O(m)$ operações; criar I requer $O(|\mathcal{C}|)$; especificar as unidades e os conjuntos admissíveis requer $O(|\mathcal{C}| \cdot m)$; e definir as funções requer tempo constante por argumento. Como X3C é NP-difícil e a reduzimos em tempo polinomial ao PEE, concluímos que o PEE é NP-difícil. $\square$

Observação 5.3 (Complexidade da forma com equidade). Como o PEE com equidade recupera a forma base quando $\delta = 0$, a Definição 5.1 é caso particular da Definição 5.2. Logo, o Teorema 5.1 implica que o PEE com equidade também é NP-difícil, sem necessidade de nova redução.

5.3 Formulação como Programação Linear Inteira

Apresenta-se agora a formulação do PEE como Programação Linear Inteira, instanciada nos dois níveis considerados, escola e turma. O efeito sobre um aluno depende conjuntamente do subconjunto implantado em sua escola e do implantado em sua turma, e essa combinação é multiplicativa, o que torna o objetivo não linear se as duas decisões forem tratadas separadamente. A linearização é feita por enumeração: como toda turma pertence a uma única escola e todos os seus alunos compartilham esses dois níveis, enumera-se, para cada turma, o par formado pelo subconjunto de sua escola e pelo subconjunto da própria turma. O número de pares por turma é $|\mathcal{S}^E| \cdot |\mathcal{S}^T| = 2^{|I^E|} \cdot 2^{|I^T|}$, uma constante pequena, e a efetividade de cada par é pré-computada, mantendo o objetivo linear.

A decisão da escola é única e compartilhada por todas as suas turmas. Por isso, além das variáveis de par por turma, mantêm-se variáveis de seleção por escola, e uma restrição de consistência garante que a componente de escola do par escolhido por cada turma coincida com o subconjunto de fato implantado em sua escola.

Conjuntos e parâmetros.

$A = \{1, \dots, n\}$	conjunto de estudantes a
Σ	conjunto de escolas σ (partição de A)
$\mathcal{T}$	conjunto de turmas t (partição de A)
$\sigma(t) \in \Sigma$	escola à qual pertence a turma t
I^E, I^T	tipos de escola e de turma, com $I = I^E \cup I^T$
$\mathcal{S}^E = 2^{I^E}, \mathcal{S}^T = 2^{I^T}$	subconjuntos admissíveis de escola e de turma
$n_\sigma = \sigma , n_t = t $	número de alunos da escola σ e da turma t
$r_a \in [0, 1]$	risco inicial de evasão do aluno a
$R_t = \sum_{a \in t} r_a$	massa de risco da turma t
$e_i \in [0, 1]$	efetividade da intervenção i
$cf_{i,\sigma}, cf_{i,t} \in \mathbb{R}_+$	custo fixo de implantar i na escola / turma
$cv_i \in \mathbb{R}_+$	custo variável de i por aluno alcançado
B	orçamento total disponível
q_i	capacidade máxima da intervenção i

A efetividade de um subconjunto e a efetividade combinada de um par são as constantes

$$\hat{e}_s = 1 - \prod_{i \in s} (1 - e_i), \quad \hat{e}_{s_e, s_t} = 1 - (1 - \hat{e}_{s_e})(1 - \hat{e}_{s_t}), \quad (5.7)$$

bem definidas porque I^E e I^T são disjuntos, de modo que o conjunto que alcança um aluno é a união sem repetição do subconjunto de sua escola com o de sua turma.

Variáveis.

$w_{s,\sigma} \in \{0, 1\}$	a escola σ recebe o subconjunto $s \in \mathcal{S}^E$
$y_{s_e, s_t, t} \in \{0, 1\}$	a turma t recebe s_t e sua escola recebe s_e
$x_{i,\sigma}^E \in \{0, 1\}$	a escola σ implanta $i \in I^E$
$x_{i,t}^T \in \{0, 1\}$	a turma t implanta $i \in I^T$

Formulação.

$$\min \sum_{t \in \mathcal{T}} R_t \sum_{s_e \in \mathcal{S}^E} \sum_{s_t \in \mathcal{S}^T} (1 - \hat{e}_{s_e, s_t}) y_{s_e, s_t, t} \quad (5.8)$$

$$\text{s.a.} \quad \sum_{\sigma \in \Sigma} \sum_{i \in I^E} (cv_i n_\sigma + cf_{i, \sigma}) x_{i, \sigma}^E + \sum_{t \in \mathcal{T}} \sum_{i \in I^T} (cv_i n_t + cf_{i, t}) x_{i, t}^T \leq B \quad (5.9)$$

$$\sum_{\sigma \in \Sigma} n_\sigma x_{i, \sigma}^E \leq q_i \quad \forall i \in I^E \quad (5.10)$$

$$\sum_{t \in \mathcal{T}} n_t x_{i, t}^T \leq q_i \quad \forall i \in I^T \quad (5.11)$$

$$\sum_{s \in \mathcal{S}^E} w_{s, \sigma} = 1 \quad \forall \sigma \in \Sigma \quad (5.12)$$

$$\sum_{s_t \in \mathcal{S}^T} y_{s_e, s_t, t} = w_{s_e, \sigma(t)} \quad \forall t \in \mathcal{T}, \forall s_e \in \mathcal{S}^E \quad (5.13)$$

$$x_{i, \sigma}^E = \sum_{s \in \mathcal{S}^E: i \in s} w_{s, \sigma} \quad \forall \sigma \in \Sigma, \forall i \in I^E \quad (5.14)$$

$$x_{i, t}^T = \sum_{s_e \in \mathcal{S}^E} \sum_{s_t \in \mathcal{S}^T: i \in s_t} y_{s_e, s_t, t} \quad \forall t \in \mathcal{T}, \forall i \in I^T \quad (5.15)$$

$$w_{s, \sigma}, y_{s_e, s_t, t}, x_{i, \sigma}^E, x_{i, t}^T \in \{0, 1\} \quad (5.16)$$

A função objetivo (5.8) minimiza o risco agregado residual, com o par escolhido em cada turma determinando o fator remanescente $(1 - \hat{e}_{s_e, s_t})$ para todos os seus alunos. A restrição (5.9) impõe o orçamento, com custo variável contado por aluno alcançado em cada nível, daí os fatores n_σ e n_t , e custo fixo cobrado uma vez por implantação. As restrições (5.10) e (5.11) limitam os alunos atendidos por cada tipo à sua capacidade, em cada nível. A restrição (5.12) obriga cada escola a escolher exatamente um subconjunto. A restrição (5.13) é a peça central da estrutura multinível: ela força a componente de escola do par escolhido por cada turma a coincidir com o subconjunto implantado em sua escola, e, somada a (5.12), garante que cada turma selecione exatamente um par. As restrições (5.14) e (5.15) amarram as variáveis de implantação às de seleção.

Restrições de equidade. Seja G a partição das escolas em grupos e, por extensão, dos alunos que as compõem. A redução de risco entregue ao grupo g é linear nas variáveis de decisão,

$$\Delta_g = \sum_{t \in \mathcal{T}: \sigma(t) \in g} R_t \sum_{s_e \in \mathcal{S}^E} \sum_{s_t \in \mathcal{S}^T} \hat{e}_{s_e, s_t} y_{s_e, s_t, t}, \quad (5.17)$$

e, com Δ_g^* pré-computado conforme a Definição 5.2 e um parâmetro $\delta \in [0, 1]$, acrescenta-se o piso

$$\Delta_g \geq \delta \Delta_g^* \quad \forall g \in G. \quad (5.18)$$

Em $\delta = 0$ o piso é inativo e recupera-se a formulação sem equidade; valores crescentes de

δ traçam a fronteira eficiência-equidade avaliada na Seção 5.4.

Observação 5.4 (Nível individual fora de escopo). A formulação considera exclusivamente os níveis de escola e turma. Caso o nível individual fosse incorporado, um aluno passaria a acumular intervenções de três níveis, o produto de sobrevivência sobre eles deixaria de colapsar em um único par, e a linearização por enumeração cresceria de forma exponencial no número de tipos individuais por aluno, conforme discutido na análise de complexidade. Esse caso não é tratado neste trabalho.

5.4 Resultados Experimentais

Capítulo 6

Conclusão e Trabalho Futuro

Referências Bibliográficas

- [1] Abdul Latif Jameel Poverty Action Lab. Costing guidelines: Collecting detailed cost data to improve the policy relevance of education evaluations. Technical report, J-PAL, 2014.
- [2] Houssam El Aouifi, Mohamed El Hajji, and Youssef Es-Saady. A hybrid approach for early-identification of at-risk dropout students using lstm-dnn networks. *Education and Information Technologies*, 29:18839–18857, 2024.
- [3] BRASIL. Ministério da Educação. Portaria nº 177, de 30 de março de 2021. *Diário Oficial da União*, (seção 1):171, 31 mar. 2021.
- [4] S. Carter, A. Dathan, K. Murphy, and C. Tangoren. Using cost-effectiveness analysis to inform decision-making: Applications in the education sector. In A. Rangarajan, editor, *The Oxford Handbook of Program Design and Implementation Evaluation*, pages 468–485. Oxford University Press, 2023.
- [5] Ricardo Paes de Barros, Samuel Franco, Laura Muller Machado, Daiane Zanon, and Grazielly Rocha. *Consequências da violação do direito à educação*. Autografia, Rio de Janeiro, 2021.
- [6] Angelina Nunes de Vasconcelos, Leogildo Alves Freires, Gleidson Diego Lopes Loureto, Gabriel Fortes, Júlio Cezar Albuquerque da Costa, Luan Filipy Freire Torres, Ig Ibert Bittencourt, Thiago Damasceno Cordeiro, and Seiji Isotani. Advancing school dropout early warning systems: the iafree relational model for identifying at-risk students. *Frontiers in Psychology*, 14:1189283, 2023.
- [7] Marco Delogu, Raffaele Lagravinese, Dimitri Paolini, and Giuliano Resce. Predicting dropout from higher education: Evidence from italy. *Economic Modelling*, 130:106583, 2024.
- [8] Jeremy D. Finn. Withdrawing from school. *Review of Educational Research*, 59(2):117–142, 1989.
- [9] Jennifer Freeman and Brandi Simonsen. Examining the impact of policy and practice interventions on high school dropout and school completion rates: A systematic review of the literature. *Review of Educational Research*, 85(2):205–248, 2015.
- [10] M. R. Garey and D. S. Johnson. *Computers and Intractability: A Guide to the Theory of NP-Completeness*. W. H. Freeman and Company, New York, 1979.

- [11] Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira. Taxas de transição, 2020.
- [12] Jill Johnes. Operational research in education. *European Journal of Operational Research*, 243(3):683–696, 2015.
- [13] R. M. Karp. Reducibility among combinatorial problems. In R. E. Miller and J. W. Thatcher, editors, *Complexity of Computer Computations*, The IBM Research Symposia Series, pages 85–103. Plenum Press, New York, 1972.
- [14] Özlem Karsu and Alec Morton. Inequity averse optimization in operational research. *European Journal of Operational Research*, 245(2):343–359, 2015.
- [15] Henry M. Levin, Clive Belfield, Peter A. Muennig, and Cecilia Rouse. The costs and benefits of an excellent education for all of america’s children. Technical report, Teachers College, Columbia University, 2007.
- [16] Markson Rebelo Marcolino, Thiago Reis Porto, Tiago Thompsen Primo, Rafael Targino, Vinicius Ramos, Emanuel Marques Queiroga, Roberto Munoz, and Cristian Cechinel. Student dropout prediction through machine learning optimization: insights from moodle log data. *Scientific Reports*, 15(1):9840, 2025.
- [17] Sérgio F. Mayerle, H. F. Rodrigues, João Neiva de Figueiredo, and D. M. D. Chiroli. Optimal student/school/class/teacher/classroom matching to support efficient public school system resource allocation. *Socio-Economic Planning Sciences*, 83:101341, 2022.
- [18] Michelle S. M. Momo, Sofie J. Cabus, Kristof De Witte, and Wim Groot. A systematic review of the literature on the causes of early school leaving in africa and asia. *Review of Education*, 7(3):496–522, 2019.
- [19] Marcell Nagy and Roland Molontay. Interpretable dropout prediction: Towards xai-based personalized intervention. *International Journal of Artificial Intelligence in Education*, 34(2):274–300, 2024.
- [20] Diego Olaya, Jonathan Vásquez, Sebastián Maldonado, Jaime Miranda, and Wouter Verbeke. Uplift modeling for preventing student dropout in higher education. *Decision Support Systems*, 134:113320, 2020.
- [21] Fotios Petropoulos, Gilbert Laporte, Emel Aktas, et al. Operational research: methods and applications. *Journal of the Operational Research Society*, 75(3):423–617, 2024.
- [22] Goran Radić, Luka Jovanović, Nebojša Bačanin, Miloš S. Stanković, Vladimir Simić, Miloš Antonijević, et al. Identifying and understanding student dropouts using metaheuristic optimized classifiers and explainable artificial intelligence techniques. *IEEE Access*, 12:122377–122400, 2024.

- [23] Russell W. Rumberger. *Dropping Out: Why Students Drop Out of High School and What Can Be Done About It*. Harvard University Press, Cambridge, MA, 2011.
- [24] Hui Shi, Nuodi Zhang, Secil Caskurlu, and Hunhui Na. Applications of machine learning for at-risk student prediction in online education: A 10-year systematic review of literature. *Journal of Computer Assisted Learning*, 41(4):e70058, 2025.
- [25] E. Vazquez, F. Haimovich, and M. Adelman. Scalable early warning systems for school dropout prevention: Evidence from a 4,000-school randomized controlled trial. Technical Report 9685, World Bank, Washington, DC, 2021.
- [26] Sandra J. Wilson, Mark W. Lipsey, Emily E. Tanner-Smith, C. H. Huang, and K. T. Steinka-Fry. Dropout prevention and intervention programs: Effects on school completion and dropout among school-aged children and youth: A systematic review. *Campbell Systematic Reviews*, 7(1):1–61, 2011.

Apêndice A

Capítulo 1 anexo 1

A.1 Capítulo 1 anexo 1 seção 1

A.2 Capítulo 1 anexo 1 seção 2